

分类号: _____

密 级: _____ 公开

U D C: _____

学 号: 6720230736

江西理工大学

硕 士 学 位 论 文

基于视觉感知的列车运行轨道分割与障碍物检测方法研究

Research on Train Running Track Segmentation and Obstacle
Detection Method Based on Visual Perception

学 位 类 别: 交通运输硕士

作 者 姓 名: 唐杨洋

学 科、专 业: 轨道交通运输

研 究 方 向: 列车视觉感知方法

指 导 教 师: 刘鸿恩副教授/崔俊锋正高级工程师

2026 年 06 月 01 日

学位论文独创性声明

本人声明所呈交的论文是本人在导师指导下进行的研究工作及取得的研究成果。据我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含已获得江西理工大学或其他教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中做了明确的说明并表示谢意。

申请学位论文与资料若有不实之处，本人承担一切相关责任。

研究生签名：唐构洋

时间：2026年6月1日

学位论文版权使用授权书

本人完全了解江西理工大学关于收集、保存、使用学位论文的规定：即学校有权保留按要求提交的学位论文印刷本和电子版本，学校有权将学位论文的全部或者部分内容编入有关数据库进行检索，并采用影印、缩印或扫描等复制手段保存、汇编以供查阅和借阅；学校有权按有关规定向国家有关部门或者机构送交论文的复印件和电子版。本人允许本学位论文被查阅和借阅，同意学校向国家有关部门或机构送交论文的复印件和电子版，并通过网络向社会公众提供信息服务。

保密的学位论文在解密后适用本授权书

学位论文作者签名（手写）：唐构洋

导师签名（手写）：刘修恩

签字日期：2026年6月1日

签字日期：2026年6月1日

摘要

自动驾驶列车是轨道交通领域的重要研究方向，列车运行过程中对前方环境的感知直接关系到行车安全与稳定。当前环境监测主要依赖视频监控与人工巡检，存在覆盖范围有限、成本高及实时性不足等问题，也难以实现站点间的持续监测。基于车载设备的视觉感知技术能够在运行过程中持续获取前方场景信息，并通过图像处理技术和视觉算法对轨道结构及障碍物进行识别，为环境感知提供数据支持。然而，轨道场景纹理复杂、目标尺度差异大，加之车载设备算力受限，使模型在精度与效率之间进行平衡。针对上述问题，本文以轨道环境视觉感知方法为背景，开展轨道分割与障碍物检测研究，并依托兴国永磁磁浮列车运行场景进行实验，构建兼顾精度、实时性与计算资源适配的感知方法，以提升列控系统的障碍物识别能力。本文主要工作如下：

(1) 针对轨道区域分割任务中模型精度与计算效率难以兼顾的问题，设计了一种融合多尺度特征与多通道注意力的轻量级轨道分割网络 LiteRailSegNet(Lightweight Rail Segmentation Network)。该网络利用部分卷积构建轻量化特征提取主干，以降低模型参数量与计算开销；设计多尺度边缘上采样特征增强网络，通过上采样与边缘增强机制强化并融合轨道中的多尺度特征；构建多通道注意力解码网络，将编码特征使用不同通道处理并结合双重注意力，提高模型对细节纹理与高层语义信息的解码能力。实验表明，LiteRailSegNet 的模型参数仅有 5.29M，计算开销 5.2GFLOPs，符合当前的车载计算设备要求，在 Railsem19 数据集上取得 86.07% mIoU 与 117.8 FPS 的推理速度；在 UAV-RS 数据集上区域交并比达到 90.05%，线交并比达到 65.45%；在自建 MTSD 数据集上 mIoU 达到 95.56%，在多个数据集上的结果表明该方法在保持较低模型复杂度的同时具有良好的分割精度与实时性能。

(2) 在提取轨道区域的基础上，针对轨道区域中障碍物尺度变化明显、小目标占比高以及车载设备对实时检测性能要求较高的问题，提出了一种基于分割先验与预训练特征的轨道交通障碍物实时检测方法 RT-ODFormer(Rail Transit Obstacle Detection Former)。所提方法采用基于 DINOv3 自监督预训练的 ConvNeXt 作为主干网络，通过多层级特征提取获取不同尺度目标的特征信息，并设计两级特征聚焦传播网络实现不同尺度特征之间的交互与信息融合，以增强模型对不同尺度目标的感知能力；在障碍物解码阶段，引入基于 Transformer 的检测头解码结构，通过全局特征建模实现对障碍物类别与位置的联合预测。在多目标障碍物数据集与行人行为数据集上的实验结果表明，模型参数量仅 4.51M，推理速度达到 152.1 FPS。同时，多目标障碍物检测中五类目标上分别取得 0.85、

0.91、0.94、0.75 和 0.94 的检测精度，在行人行为检测中取得 63.1% mAP_{50} 和 45.3% $mAP_{50:95}$ ，模型在不同尺度目标检测中均具有较好的性能，其中小目标检测召回率达到 84%，验证了所提方法在远距离障碍物感知与漏检方面的有效性。与多种检测方法相比，本方法在检测精度、计算复杂度与实时性之间取得了更好的平衡。

本文利用图像处理技术实现了从轨道区域结构感知和区域内障碍物检测，为列车避障系统中的视觉感知模块提供了一种兼顾实时性与准确性的技术方案，可以为轨道交通智能安全监测与自动驾驶列车环境感知系统的设计提供参考。

关键词：轨道交通系统；视觉感知；图像处理；轨道区域分割；障碍物检测

Abstract

Autonomous train operation has become an important research direction in the field of rail transit, where environmental perception during train operation is closely related to operational safety and stability. Current environmental monitoring methods mainly rely on video surveillance and manual inspection, which suffer from limited coverage, high labor costs, and insufficient real-time performance, making continuous monitoring between stations difficult to achieve. Vision-based perception technologies using onboard devices can continuously acquire forward-scene information during train operation. By combining image processing techniques with visual algorithms, track structures and obstacles can be identified, thereby providing essential data support for environmental perception. However, the complex textures of rail scenes, significant variations in target scales, and limited onboard computational resources make it challenging to balance model accuracy and efficiency. To address these issues, this thesis investigates rail-environment visual perception methods, focusing on rail segmentation and obstacle detection tasks. Experiments are conducted based on the operational scenarios of the Xingguo permanent-magnet maglev railway system. The objective is to develop perception methods that achieve a balance among accuracy, real-time performance, and computational efficiency, thereby improving the obstacle recognition capability of train control systems. The main contributions of this thesis are summarized as follows:

(1) Aiming at the problem that is difficulty to balance accuracy and computational efficiency in track region segmentation, a lightweight rail segmentation network named LiteRailSegNet (Lightweight Rail Segmentation Network) is proposed, which integrates multi-scale feature extraction and multi-channel attention mechanisms. A lightweight feature extraction backbone based on partial convolution is employed to reduce model parameters and computational overhead. In addition, a multi-scale edge-enhanced up sampling module is designed to strengthen and fuse multi-scale rail features through up sampling and edge enhancement operations. Furthermore, a multi-channel attention decoding network is constructed to process encoded features through different channel branches combined with dual-attention mechanisms, thereby improving the decoding capability for detailed textures and high-level semantic information. Experimental results demonstrate that LiteRailSegNet contains only 5.29M parameters with 5.2 GFLOPs, satisfying the computational requirements of onboard devices. The proposed method achieves 86.07% mIoU with an inference speed of

117.8 FPS on the RailSem19 dataset, 90.05% region IoU and 65.45% line IoU on the UAV-RS dataset, and 95.56% mIoU on the self-constructed MTSD dataset. Results on multiple datasets verify that the proposed method achieves favorable segmentation accuracy and real-time performance while maintaining low model complexity.

(2) Based on the extracted rail regions, a real-time rail-transit obstacle detection method named RT-ODFormer (Rail Transit Obstacle Detection Former) is proposed to address the challenges of significant object scale variation, a high proportion of small targets, and strict real-time requirements in complex rail scenarios. The proposed method employs a ConvNeXt backbone pretrained with the DINOv3 self-supervised learning strategy to extract multi-level semantic features for objects at different scales. Moreover, a two-level feature focus propagation network is designed to facilitate cross-scale feature interaction and information fusion, thereby enhancing the perception capability for multi-scale targets. During the obstacle decoding stage, a Transformer-based detection head is introduced to jointly predict obstacle categories and locations through global feature modeling. Experimental results demonstrate that RT-ODFormer contains only 4.51M parameters and achieves an inference speed of 152.1 FPS, satisfying the real-time requirements of rail transit visual perception tasks. In the multi-object obstacle detection task, the proposed method achieves detection accuracies of 0.85, 0.91, 0.94, 0.75, and 0.94 for five object categories, respectively. On the pedestrian behavior detection dataset, the model achieves 63.1% mAP₅₀ and 45.3% mAP_{50:95}. Furthermore, experiments on targets of different scales show that the proposed method maintains robust detection performance, with a recall rate of 84% for small objects, demonstrating its effectiveness in distant obstacle perception and missed-detection risk reduction. Compared with several mainstream detection methods, the proposed approach achieves a better balance among detection accuracy, computational complexity, and real-time performance.

In this thesis, image processing techniques are utilized to achieve both structural perception of rail regions and obstacle detection within rail areas. The proposed methods provide an effective technical solution for visual perception modules in train obstacle avoidance systems and can serve as a reference for the design of intelligent safety monitoring systems and autonomous train environmental perception systems in rail transit applications.

Key Words: Rail transit systems; Visual perception; Image processing; Track region segmentation; Obstacle detection

目录

摘要	I
Abstract	III
第一章 绪论	1
1.1 研究背景	1
1.2 研究目的及意义	3
1.3 研究现状	4
1.3.1 基于深度学习的视觉感知方法	4
1.3.2 基于图像分割的轨道提取方法	6
1.3.3 基于目标检测的轨道障碍物识别	7
1.4 论文章节安排	9
1.5 本章小结	10
第二章 列车视觉感知理论基础	11
2.1 网络架构组成	11
2.2 图像分割技术	13
2.3 目标检测方法	15
2.4 分割与检测评价指标	20
2.5 本章小结	21
第三章 融合多尺度特征与多通道注意力的轻量化轨道分割方法	22
3.1 分割网络架构	22
3.2 轻量化编码网络	23
3.3 多尺度边缘上采样特征增强网络	24
3.4 多通道注意力解码网络	26
3.5 实验分析	27
3.5.1 实验设置与数据集	27
3.5.2 铁路场景实验	31
3.5.3 无人机视角实验	33

3.5.4 自建空轨数据集实验	34
3.5.5 消融实验	35
3.6 本章小结	36
第四章 基于分割先验和预训练特征的障碍物检测方法	37
4.1 检测网络架构	37
4.2 基于预训练的特征编码网络	38
4.2.1 自监督视觉特征建模	39
4.2.2 特征编码主干网络	40
4.3 两级特征聚焦传播网络	43
4.4 检测头优化	45
4.5 实验结果分析	46
4.5.1 实验设置与数据集	46
4.5.2 多目标障碍物实验	48
4.5.3 行人行为检测实验	51
4.6 本章小结	55
第五章 总结与展望	56
5.1 全文工作总结	56
5.2 未来研究展望	57
参考文献	58
致谢	63
攻读学位期间的研究成果	64

第一章 绪论

1.1 研究背景

党的二十大以来,我国铁路的线路规模、动车组质量和智能化水平得到明显提升,客货运输周转量、专利技术创新、能源节能环保、效率快速安全等指标稳居于世界前列,为我国经济高质量发展给与了交通上的保障。《新时代交通强国铁路先行规划纲要》中指出铁路作为经济建设的重要支柱,既是构建现代化经济体系的重点领域,也为全面建成社会主义现代化强国提供坚实保障,而轨道交通作为城市交通运输体系的核心组成部分,越来越多的城市开通了运行线路,截至到 2024 年底,我国的轨道交通营业里程超过 12000 公里,运营城市达到 58 个,运营路线 361 条,如图 1.1 所示,轨道交通制式包括地铁、轻轨、有轨电车、磁浮列车等^[1]。随着交通强国计划的不断推进,城市轨道交通规模持续扩大,在公共交通中发挥的骨干作用更加明显。中低速磁浮列车作为一种新型轨道交通工具,因其具有低噪音、安全环保、较强的爬坡能力以及小转弯半径等传统交通工具所不具备的优势,受到广泛关注。目前,长沙机场线、北京磁浮 S1 线等低速磁浮线路已投入商业运营,同时凤凰磁浮旅游快线和兴国红轨永磁磁浮示范线^[2]等项目也在积极建设中,多条最高时速可达 200km/h 的中速磁浮线路正在规划当中,随着这些项目的落地,磁浮交通有望成为 21 世纪重要的现代化交通方式。




图 1.1 轨道交通制式

随着我国铁路网规模的不断扩大，对铁路安全保障系统提出了更高的要求。虽然列车运行环境相对封闭，但也无法避免运行过程中的障碍物侵入^[3]，近年来，因人为因素、自然因素等引起的障碍物侵限问题无法完全规避，若未对这些侵限物体进行及时的处理，可能对行车安全造成严重影响，比如 24 年 11 月南京地铁动物侵入造成列车晚点，24 年 12 月上海地铁因外部塔吊倒塌侵入列车行驶区域，造成线路设施和列车受损。因此，列车主动避障系统作为直接与外部环境交互的眼睛，是确保列车安全运行的核心组成部分，其性能直接影响到轨道交通系统的安全性、运营效率和乘客舒适度，同时更是列车获得行车许可和安全载客的前提条件，进而为列车安全行驶提供重要支撑，而障碍物检测技术是主动避障系统的基础技术之一。因为列车运行速度较快、惯性大，一旦出现障碍物，传统制动方式难以迅速停靠，极易导致安全事故，因此保证列车运行轨道上及附近没有影响列车运行的障碍物是保障行车安全的首要任务，这就对列车的障碍物主动探测技术提出了更高的要求。传统的人工巡检方式受到环境、检测人员的影响，无法满足轨道交通系统向智能化方向发展的要求。因此，深入研究列车前向障碍物探测技术，确保能精确、快速检测到环境中的障碍物信息，以实现列车的安全运行，已成为轨道交通领域的重要课题，也是轨道交通智能化发展的必然要求。

目前的轨道障碍物检测主要分为两种类型：接触式检测和非接触式检测。接触式检测主要通过安装在轨旁、轨道下、列车行进沿途安装接触型传感器实现障碍物的侵入检测^[4]，而非接触式检测则是利用相机、雷达、红外探测等非接触式传感器探测障碍物^[5]。由于接触式检测是在固定位置安装检测设备，但随着列车运行环境的复杂化，接触式检测方法无法在快速变化的运行环境中做到实时监测，而且安装维护成本过于高昂。而目前主流的检测技术主要还是以非接触式为主，如图 1.2 所示，通过在列车上安装各类环境监测传感器作为列车的感知系统，结合人工智能技术，不仅能做到高精度、实时的障碍物检测，还能实现准确的避障预警^[6]。




图 1.2 非接触式检测

由于列车在运行中会面临着环境中的不确定性因素，所以避障系统需要考虑到各种复杂情况，一些因素会导致列车视觉设备的障碍物检测性能受到影响。目前基于图像处理的障碍物检测技术需要依赖嵌入式设备的处理能力，即使随着硬件资源的发展，算力的限制逐渐降低，但还是需要考虑模型的轻量化，使得模型能够在边缘计算设备上部署。再者，当前的检测方法是依赖预标注类别的数据，通过有监督的方式让模型学习特定障碍物的视觉特征，但列车通常是在开放的动态环境中运行，这种情形面临的障碍物类别和尺度多变，传统的检测方式难以覆盖所有潜在的障碍物类型，因此通过引入预训练特征提取方法，可利用其在大量数据上学习到的通用视觉特征表达能力，对物体的语义和几何特征进行初步的建模。这种新范式不仅能识别已知障碍物，也能利用特征匹配与提升对未知类别障碍物的感知与识别能力，从而提升避障系统的性能。

综上所述，本课题利用视觉感知技术，针对列车运行中的避障方法展开研究，设计有效的轨道区域分割方法和列车障碍物检测方法，实现对列车避障系统可靠性和安全性的有效提升，丰富列车避障系统的理论。课题研究成果对于发展我国列车运行安全控制技术，提高我国列车的自动驾驶水平，推动我国城市轨道交通事业发展和建设交通强国具有重要意义。

1.2 研究目的及意义

在我国铁路特别是高速铁路和城市轨道交通的快速发展的背景下，列车运行速度不断提高，运行环境日益复杂，列车主动安全防护能力需要的达到的性能更高，传统依赖人工检查或普通自动防护系统的避障手段，已难以满足复杂场景下对安全性和实时性的综合需求。基于视觉感知的列车前向障碍物检测技术，因其检测技术可靠、设备安装维修简便、易于部署等特点，逐渐成为列车主动避障系统中的一个重要技术分支。然而，实际运行环境中仍存在轨道区域背景干扰、目标尺度不一、障碍物类别多样且数据样本稀缺等问题，严重制约了检测方法的发展和系统的稳定性。

本方法以列车实际运行环境为研究背景，围绕轨道区域分割—障碍物检测这一技术路线，重点研究基于轨道区域分割的列车前向主动避障方法。通过精准提取轨道及其周边环境的信息，抑制无关背景干扰，引导后续障碍物检测模型聚焦高风险区域，从而在有限车载计算资源条件下，实现对轨道前方潜在障碍物的高效、准确识别。研究目标在于构建一种兼顾精度、实时性与工程可落地性的列车前向障碍物检测方法，为列车运行安全提供可靠的技术支撑。

针对轨道交通场景中背景结构复杂、轨道与周边环境视觉特征相似度高的问题，本文以区域分割为切入点，深入研究轨道区域的精确快速提取方法，为列车前向视觉信息

的场景化理解提供技术方案。首先通过分割方法将轨道区域作为先验信息，然后引导障碍物检测模型关注列车实际行驶的轨道区域，有效降低非轨道区域对检测结果的干扰，以降低因为环境变换导致的像素分布不均等问题带来的干扰。本研究有助于提升列车视觉感知系统对的感知能力，为复杂铁路环境下的智能避障提供新的技术思路，研究成果可为列车主动安全防护系统提供主要的算法方案，提升系统对轨道区域识别、障碍物侵限、行人闯入等高风险事件的预警能力，对减少事故发生具有实际应用意义。

列车运行环境感知是实现轨道交通智能化的重要基础，本文围绕轨道区域分割和障碍物检测展开系统研究，有助于完善列车视觉感知技术体系，推动相关算法向工程化、实用化方向发展。研究成果不仅可应用于列车避障系统，还可为轨道巡检、基础轨道设施状态监测等任务提供技术借鉴，对提升我国轨道交通设备的智能化水平具有积极意义。

1.3 研究现状

本节首先回顾深度学习中计算机视觉技术的发展历程，阐述了从经典图像处理技术到现代模型的迭代，为本文的方法研究奠定技术基础。然后分别说明计算机视觉技术在轨道交通场景下的两大应用，基于图像分割的轨道提取方法，综述图像分割方法在轨道提取领域的应用；基于目标检测的轨道异物识别方法，论述对各种检测模型的在异物侵入上的实际应用。通过这种从通用技术到专用场景的论述，为本文后续的轨道分割与障碍物检测研究提供清晰的理论支撑。

1.3.1 基于深度学习的视觉感知方法

计算机视觉(Computer Vision, CV)是一门研究让计算机模拟人类视觉功能的学科，它使计算机具备获取、处理、解析和理解静态图像及动态视频序列的能力，从而为智能系统的开发奠定基础。近年来，该领域的技术革新持续推动着应用范围的扩大，同时也在识别精度和运算速度上取得了显著提升。以深度学习为代表的算法技术创新，不仅增强了机器学习在语义分割和目标检测等任务中的表现，更促进了相关技术在多个领域中的交叉结合与创新应用。

2012 年，AlexNet 在 ImageNet 大规模视觉识别竞赛中取得了具有里程碑意义的成果^[7]，该模型首次使用并行 GPU 计算方法，ReLU 激活函数、Dropout 正则化策略等创新技术，极大的提升了图像分类任务的整体性能，这一进展被认为推动了深度学习技术在计算机视觉领域的快速发展与广泛应用。此后，基于卷积神经网络（Convolutional Neural Networks, CNN）的方法逐渐成为图像分类、目标检测和语义分割等任务的主流技术框架。如图 1.3 所示，一个经典的 CNN 架构通常包含输入层、多个卷积层、池化

层、批归一化层、全连接层等核心组件。随着研究的深入，更复杂的结构不断涌现，如 GoogleNet 提出的多尺度特征融合模块^[8]、VGGNet 的小卷积核堆叠深层均匀架构^[9]以及 ResNet 的残差连接^[10]等。这些创新不仅推动了模型性能的提升，也促进了计算机视觉技术在自动驾驶、医学图像、工业自动化检测等领域的广泛应用。




图 1.3 CNN 经典架构

随着技术的不断更新，Transformer 的提出为深度学习的发展开辟了新的研究方向，该模型最初主要用于处理自然语言处理及其他序列到序列任务，是一种基于注意力机制的深度学习架构，并由 Vaswani 等人在 2017 年首次提出^[11]。而后，Transformer 架构被引入机器视觉领域，Dosovitskiy 等人提出的 ViT 模型^[12]实现了 Transformer 架构在机器视觉任务中的应用，并在该领域的发展过程中具有代表性意义，其基于自注意力机制的架构展现出更强的全局建模能力在大规模数据集上取得了由于传统 CNN 的能力。随之而来的 Swin Transformer^[13]、MAE^[14]等改进版本进一步提升了计算效率，使 Transformer 架构在各类视觉任务中展现出前所未有的优势。

随着基础模型的不断进化，计算机视觉的研究前沿正在向多模态融合方向快速拓展。OpenAI 提出的 CLIP 模型开创性地实现了视觉—语言表征的对齐^[15]，而 DALL-E^[16]、Stable Diffusion^[17]等生成模型则展示了跨模态技术的潜力。为满足实际部署需求，研究者在模型效率优化方面也取得了显著进展，从 MobileNet 的深度可分离卷积到 YOLO 系列^{[48]-[57]}的实时目标检测算法，轻量化技术正在推动计算机视觉走出实验室，走进智能手机、自动驾驶车辆和工业检测器材等各类与人生活息息相关的边缘设备。

1.3.2 基于图像分割的轨道提取方法

图像分割是计算机视觉领域中的一个基本问题，在图像分割领域，基于深度学习的方法始于 2014 年，尤其是全卷积神经网络(FCN)的提出^[18]，标志着在语义分割任务中首次实现了端到端的网络训练和像素级预测，该网络结构不仅开创了深度学习在语义分割领域的应用，还为后续网络框架的改进提供了基础。继 FCN 之后，众多改进的语义分割模型相继涌现，U-Net 网络以其开创性的编码—解码框架为图像分割奠定了基础，不过 U-Net 网络在分割精度上略有不足。DeepLabv1~v3+ 系列网络采用空洞卷积、CRF 以及特征金字塔等方法增强语义理解能力，大幅提高了模型的分割精度，但同时也为模型带来了庞大的计算资源开销，限制了实际使用^[19-20]。为了兼顾好计算资源和分割精度，BiseNet^[21]、MobileNet^[22]、Fast-SCNN^[23]等轻量级模型应运而生，但不可避免的在一定程度上牺牲了分割精度。近年来，随着 Transformer 架构被引入视觉任务，也为分割技术带来新的方向。如 ViT^[24]、Swin Transformer^[25]等方法在多个分割任务上取得了优异的结果。但基于 Transformer 的视觉模型通常具有较大的参数量和计算量，这极大的限制了这一类模型的实际应用，为了应对这一挑战，SegFormer 将 Transformer 与轻量级多层感知机解码器结合，以寻求更低的计算开销，成为了兼顾性能与效率的重要代表^[26]。

图像分割方法已从注重模型深度逐步向结构简洁、推理高效的方向演进，大量研究表明，编解码架构的模型更有利于图像分割。这种方法首先通过编码器对输入图像进行压缩，然后逐步地提取包含高层语义信息的特征图，最后借助解码器对这些高层特征进行逐步上采样，将其恢复至输入分辨率，从而实现端到端的像素级密集预测任务，最终完成语义分割。编码器-解码器结构更能提取图像的深层特征信息和无损恢复特征信息，以提高分割结果的准确性和细节表示^[27]。基于上述特点，本文所设计的模型采用了编码器—解码器整体框架，以进一步保障分割性能。

轨道是铁路系统中的基础设施，轨道区域的精确识别是保障列车运行安全的前提。传统的轨道检测方法在效率与环境适应性方面存在局限性，近年来基于深度学习的分割方法在轨道识别任务中展现出了巨大潜力，能增加轨道识别的准确性和稳定性。

Wang 等人改进特征金字塔网络以增强特征提取能力，提出 RailNet 从而改善识别精度，但是模型复杂度较高，需要依赖计算良好的计算能力^[28]。Belyaev 等人提出一个在用于高分辨率图像进行轨道分割的网络，该方法通过改进特征金字塔网络和注意力网络以增强特征提取能力，从而提高预测精度，但是模型复杂度高，需要依赖良好的计算能力^[29]。Yang 等人通过在 DeepLab 模型的基础提出一种 DFR 方法，用于提高轨道分割精度，在无人机数据集上实现了较高的 mIoU，但 DeepLab 模型参数量过大，且检测速率较低^[30]。路通等提出一个多尺度特征融合模块，嵌入主干网络以获取不同尺度特征，再

结合双通道注意力模块进一步增强特征提取性能,在 Railsem19 数据集上实现了 66.12% 的 mIoU^[31]。郑泽熙等人将 MobileNetv2 网络结合 Mask-RCNN 网络优化改进,构建轻量检测模型,兼顾分割精度和效率^[32]。Zhou 等人利用一种跨阶段模块减少网络的计算开销,并在主干网络中加入池化金字塔用于轨道交通的语义分割,在 Cityscapes 上达到了 64 FPS^[33]。Feng 等人提出 LRseg 模型,采用自校正特征融合模块和级联结构,有效的利用了上下文信息和空间信息,并在分割部分引入金字塔池化模块,提高了模型的分割速度^[34]。Wei 等人基于 YOLACT++, 结合先验知识,提出一种铁路轨道线分割模型,通过在检测头中引入特征增强方法,以此提高检测精度,该模型在自建数据集上实现了较高的准确率,但检测速度过低^[35]。刘朝辉等人利用 MobileNetv3 为主干编码器,采用编解码框架构建了一个轻量轨道分割模型,在自建数据集上实现了较高的精度^[36]。

综上所述,基于图像分割的轨道区域提取方法在铁路自动化检测中展现出可行的技术优势和应用潜力。上述研究在分割精度、实时性和特定环境适应性方面各有优势,但大多数模型仍面临计算资源消耗大、部署适配性差、泛化能力低等挑战。因此,本文研究以实际工程应用为立足点,在保证精度的前提下,兼顾好实时性、轻量化和环境适应能力,推动轨道提取技术向更高效、更稳定的方向发展,为轨道交通安全运营提供技术支撑。

1.3.3 基于目标检测的轨道障碍物识别

目标检测是深度学习领域中的另一个核心任务,旨在识别图像数据中的物体并标记它们的位置和类别。传统的目标检测算法常用多阶段处理,存在计算量大且速度慢的问题,例如,用于行人检测的 SVM、DMP 等方法。随着深度学习的兴起,目标检测任务开始利用 CNN 作为主要技术,基于深度学习的目标检测方法主要分为两个分支:两阶段检测器和单阶段检测器。两阶段模型 R-CNN 系列^[37-38],通过引入区域提议网络和端到端训练,提升了目标检测的精度,但两阶段框架计算开销大,检测速度较慢,在实时性要求较高的场景难以应用。为解决这一问题,Redmon 等人在 2016 年提出 YOLO 模型,随后 SSD 等方法也出现。这类单阶段方法省去区域提议步骤,直接从图像中预测目标位置与类别,在保证检测性能的同时提升了检测速度。YOLO 系列模型是目标检测领域的前沿技术,但单阶段模型在检测精度上通常不如双阶段模型。随着 Transformer 技术的横空出世,不少研究者将目光瞄准了基于 Transformer 架构的目标检测,FaceBook 团队在 2020 年利用 Transformer 的序列建模能力,提出了 DETR 模型,通过编码器—解码器架构来简化检测流程,将目标检测视为直接的集合预测问题,实现端到端的检测,后续该团队又结合了可变形卷积,提出了 RT-DETR 模型。在创新过程中,VITDet、DINO

等模型在目标检测领域展现了相当大的潜力。然而，基于 Transformer 的检测模型通常需要大量计算资源，并且模型参数巨大，这使得它们在边缘设备上的应用陷入了瓶颈。

在轨道交通领域，国内外学者已开展了一系列基于计算机视觉的障碍物检测研究。传统的轨道障碍物检测方法主要依赖人工巡视或接触时检测，这些方法虽然在特定场景下具有一定的实用价值，而对于由山体滑坡、塌方、泥石流等自然灾害，前车、行人、动物等随机障碍物造成的异物侵入，尚没有成熟的检测系统，仅依靠在关键点架设监控器等视觉设备，无法对突发情况做到有效监测。近年来，基于深度学习的轨道障碍物检测方法逐渐成为研究热点，通过部署相机等视觉设备并结合目标检测算法，可以实现对轨道区域的连续监控和自动识别，极大地提升了检测效率与准确率。

深度学习算法在交通监控、自动驾驶、智能安防等领域被广泛应用，其高效的特征提取能力和检测速度为轨道障碍物检测提供了良好的算法基础。He 等人利用 YOLOv4，通过改进特征提取网络，并将之部署于嵌入式系统中，提高模型的处理速度和精度的同时，还能够布置于移动端，使之能够更加方便地运用于轨道交通的障碍物检测^[39]。Zhang 等人以 YOLOv5 为主干网络，对轨道交通的异物入侵提供了一种预警机制方法，通过将轨道划分为轨道中心和轨道两边的风险区域，通过计算障碍所处的位置，评估所处的风险等级，根据评估结果以帮助相关人员采取不同的行动，确保行车安全^[40]。王楠等人对 YOLOv7 网络进行改进，引入注意力机制模块，增强复杂环境下的特征提取能力，同时，将原网络的卷积层替换，降低模型参数量^[41]。Qin 等人针对小目标障碍物，利用全局知识蒸馏提高了特征提取能力，设计一种鲁棒特征注意力网络，对小目标检测具有显著增强效果^[42]。Zhang 等人为了应对检测算法在边缘设备上部署困难的问题，提出了一种轻量级的障碍物检测网络，该网络通过使用并行空间通道卷积，以局部并行连接策略，用较少的参数和计算负担表现出高性能的障碍物检测能力。此外，基于硬件设施性能的提高，有学者利用雷达设备作为传感器获取列车前向视野数据^[43]。戴鸿辉等人利用激光雷达作为主要传感器，提出一种利用 3D 特征的非接触式障碍物检测算法，有效实现了障碍物的检测^[44]。Zhu 等人设计了一种激光测距系统，该系统能够自主调整成像范围和角分辨率，能够在 50m 的监控区域内实现高精度成像。此外，基于配准和一系列滤波算法，建立了一种铁路表面障碍物提取算法^[45]。

综上所述，尽管基于深度学习的轨道障碍物检测方法取得了一定的研究成果，但這些研究中仍面临诸多挑战。首先，复杂多变的自然环境因素如雨雪雾、强光等会对视觉传感器的成像质量造成严重影响，进而降低检测算法的可靠性。其次，轨道场景中的小目标检测问题尚未得到根本解决，特别是远距离处的行人或小型障碍物容易漏检。此外，现有算法在实时性方面仍需优化，尤其是当需要同时处理多路高清视频流时，计算资源消耗较大。因此，本文研究重点关注实际一个更强的特征识别能力的检测算法，提升模

型对各种障碍物的识别能力；二是优化轻量化网络设计，平衡好精度和计算开销；三是利用更多样的轨道障碍物数据集，覆盖各种天气条件、光照变化和障碍物类型，为算法训练和评估提供更泛化的基础。

1.4 论文章节安排

本文一共分为五个章节，每个章节的研究内容以及章节安排如图 1.4 所示。本文围绕轨道交通场景下列车避障系统中的视觉感知模块展开研究，针对复杂轨道环境中列车安全运行对实时性与可靠性的高要求，研究利用深度学习技术实现视觉感知任务的有效解决方案。在分析轨道交通场景视觉感知任务特点的基础上，本文从列车避障应用需求出发，重点研究了轨道区域的快速、准确分割方法以及面向轨道区域的通用障碍物检测技术。通过对轨道区域这一关键感知先验的建模与利用，有效缩小视觉感知范围，降低背景干扰，为后续障碍物检测与风险判断提供可靠的空间约束。




图 1.4 论文章节安排

第一章为绪论，主要介绍本文的研究背景、研究目的及研究意义，并对轨道交通视觉感知领域的国内外研究现状进行分析。在此基础上，结合复杂轨道场景下列车环境感知任务面临的问题与挑战，明确本文的研究内容、技术路线以及论文整体结构安排。

第二章为相关理论与关键技术，主要介绍本文研究所涉及的深度学习基础理论，以及图像分割与目标检测相关方法。首先对深度学习网络结构与基本原理进行说明，随后分别介绍语义分割与目标检测领域的典型算法及技术特点，并对实验中所采用的评价指标进行说明，为后续轨道区域分割与障碍物检测方法研究提供理论基础与技术支撑。

第三章针对复杂轨道场景下轨道区域分割任务中精度与实时性难以兼顾的问题，提出一种轻量化轨道区域分割方法。围绕模型整体结构、轻量化特征提取、多尺度特征融合以及注意力解码机制等内容展开研究，并结合公开数据集与自建数据集，对所提方法的分割性能、实时性及模型复杂度进行实验分析与验证。

第四章在轨道区域分割的基础上，针对轨道区域内潜在障碍物的实时检测问题，提出一种轨道交通障碍物检测方法。重点围绕多尺度特征提取、特征交互融合以及基于Transformer的目标解码结构展开研究，并通过多类障碍物场景实验，对模型的检测精度、推理速度及场景适应能力进行分析与验证。

第五章为总结与展望，对本文围绕轨道交通视觉感知所开展的研究工作进行总结，归纳轨道区域分割与障碍物检测方法的主要研究内容与实验结果，并结合轨道交通智能感知技术的发展趋势，对未来研究方向进行展望。

1.5 本章小结

本章主要对本文的研究背景、研究目的及意义以及相关研究现状进行阐述。指出了在轨道场景下视觉感知任务面临的一些挑战，并围绕列车避障系统对实时性与感知精度的应用需求，说明了本文的研究目标与研究内容。在此基础上，分别从基于深度学习的计算机视觉技术、基于图像分割的轨道提取方法以及基于目标检测的轨道异物识别方法三个方面分析了当前的研究现状，明确了本文的研究技术路线，并概述了各章节的安排。

第二章 列车视觉感知理论基础

2.1 网络架构组成

(1) 骨干网络

骨干网络通常被称为 **Backbone**，可以看作深度学习视觉模型中的编码部分之一，主要负责对输入图像进行逐层特征提取，并逐步形成从低层到高层的多层次特征表示。在一个网络结构当中，**Backbone** 相当于整个模型的主体结构，为后续分类、目标检测和语义分割等任务提供基础特征支持。常见的 **Backbone** 多由深层卷积神经网络或类似结构构成，用来完成特征表达与信息提取。

Backbone 的特征提取层通常由多层卷积、归一化层和非线性激活函数堆叠而成。网络前几层更多关注边缘、角点、纹理、颜色这些比较基础的视觉信息；当网络不断加深后，感受野逐渐扩大，提取到的特征也开始包含局部结构、语义部件，甚至整体目标的信息。这种由浅到深的逐级表征方式，其实也是卷积神经网络能够在计算机视觉任务中取得良好效果的一个原因。

在实际应用中，**Backbone** 往往会直接选用在大规模图像分类数据集 ImageNet 上预训练好的模型，比如 VGG、ResNet、DenseNet、EfficientNet，以及这几年逐渐流行的 ViT 及其变体。通过迁移学习，这类模型可以提供较好的初始参数，不需要从头训练，收敛过程也会更快，同时在检测或分割任务上的表现通常也更稳定一些。

从发展趋势来看，**Backbone** 的设计不再只是单纯追求更强的特征表达能力，还需要在计算开销、参数规模和运行速度之间做取舍。比如在实时检测或嵌入式设备中，通常更倾向于选择轻量化结构；而在对精度要求较高的场景下，则可能采用更深层或多分支的网络来提升表达能力。因此，在具体应用时，**Backbone** 的选择往往需要结合任务需求，在精度、速度以及资源消耗之间找到一个合适的平衡点。

(2) 颈部

颈部又称 **Neck** 层，位于骨干网络与检测头之间，可以理解为一个过渡层。单独使用 **Backbone** 最后一层特征图虽然具备较强语义信息，但分辨率较低，容易忽略小目标，而如果只依赖浅层特征图，虽然细节丰富，却缺乏足够的语义表达能力，分类效果往往不理想。**Neck** 的引入，正是为了在这两者之间做一个调和，在已有特征的基础上进行融合与增强，使得到的表示在不同尺度下都更具适应性。

由于 **Backbone** 的不同层输出特征在分辨率、语义层次以及感受野上差别明显，如

果直接把某一层特征送入后续头部处理，很难同时兼顾大目标和小目标的检测需求。Neck 通常会引入多尺度融合机制，通过上采样、下采样、横向连接，以及特征拼接或逐元素相加等操作，把不同层的信息整合起来，从而缓解这个问题。

在过往的研究中，特征金字塔网络（Feature Pyramid Network, FPN）是一种具有代表性的结构。该方法通过自顶向下的信息传递路径，并结合横向连接机制，将高层语义信息逐级融合到高分辨率特征图中，使不同尺度的特征均具备一定的语义表达能力^[46]。在 FPN 基础上，又发展出了 PANet、BiFPN、NAS-FPN 等结构，这些方法从信息流动方式、特征加权以及结构设计等方面做了不少改进，多尺度融合效果也随之有所提升。

在实际模型中，Neck 并不只是简单地做特征拼接，它还承担着语义对齐、尺度补偿以及信息整合等任务。Neck 层的设计，往往会影响模型在尺度变化、遮挡情况、小目标识别以及复杂背景下的表现。因此，在目标检测和分割模型中，Neck 的重要性已经逐渐接近 Backbone，需要在设计时给予足够关注。

（3）头部

头部也叫 Head 网络，位于整个视觉模型的末端，可以看作最终完成预测与输出的模块，其主要依据 Neck 阶段得到的特征图来进行具体任务的决策。Head 的设计方式会直接影响模型的输出形式以及训练目标，不同任务下往往差别也比较明显。

对在分割任务中，Head 一般会在检测结构的基础上增加掩码预测分支，用于实现像素级的目标划分。相比于仅进行检测，这类结构需要在保留空间细节的同时融合高层语义信息，因此整体设计会更复杂一些。例如在 Mask R-CNN 中，其 Mask Head 通过额外的卷积子网络来完成更细致的分割预测。

对于目标检测任务来说，Head 通常需要同时处理分类和定位两个方面。分类分支主要判断目标类别，而回归分支则负责预测边界框的相关参数，比如中心位置、宽高或者偏移量等。根据检测方式的不同，Head 还可以分为基于锚框和无锚两种类型，这两类方法在输出形式以及损失函数设计上也存在一定差异。

基于近几年的研究趋势，Head 的结构逐渐朝着解耦和任务细化的方向开展。将分类与回归分支在结构上分开处理，可以在一定程度上减弱相互之间的干扰，使训练过程更稳定，预测结果也更可靠。同时，不同视觉任务对 Head 的需求并不完全一致，这也使得 Head 逐渐呈现出更强的任务针对性。

综合来看，Backbone、Neck 和 Head 共同构成了当前视觉模型的基本框架。Backbone 负责提取特征，Neck 对多尺度信息进行融合与调整，而 Head 则完成最终的预测输出。三者分工相对清晰，又相互配合，这种结构在实际应用中也比较灵活，便于后续优化和部署。

2.2 图像分割技术

视觉图像分割的目标是将输入的图像或视频在像素层面划分为若干具有语义意义的区域，这也是计算机视觉中的一个基础问题。在实际应用中，这类技术已经被广泛用于自动驾驶、图像编辑、医学图像分析以及机器人等场景。传统分割方法通常包括基于阈值的分割、边缘检测以及区域生长等策略，这些方法实现相对直接，但对人工特征的依赖较强。一旦场景变得复杂，比如光照变化明显或目标边界不清晰时，其效果往往不太理想。相比之下，基于 CNN 的方法能够通过数据学习更具表达能力的特征，在不同场景下表现更为稳定，也更容易适应复杂环境。因此，在相当长一段时间内，CNN 结构一直是图像分割研究中的常见方法。

图像分割的目标是对输入图像进行像素级别的语义划分。设输入图像为 $I \in \mathbb{R}^{H \times W \times C}$ ，其中 H 、 W 和 C 分别表示图像的高度、宽度和通道数，在这一任务中，需要学习一个映射函数 $f(\cdot)$ ，使得图像中的每一个像素都能够被分配到预先定义好的语义类别集合 $f: I \rightarrow Y, Y \in \{1, 2, \dots, K\}^{H \times W}$ 中，其中， K 表示类别总数。根据类标签和像素范围，图像分割可以分为语义分割、实例分割和全景分割三种不同的任务。类标签可以是前景对象或背景，每个类只有一个二进制掩码，表示属于该类的像素，每个掩码与其他掩码不重叠。

自 2015 年 U-Net 提出以来，图像分割方法的发展进入了一个新的阶段。该网络通过引入 U 型结构的编码器—解码器设计，并结合跳跃连接机制，使得模型在提取高层语义信息的同时，也能够保留底层细节信息，因此在医学图像处理领域取得了较好的效果。受此影响，后续大多数分割网络也逐渐采用类似的编码器—解码器结构。

一个典型的编码器—解码器框架如图 2.1 所示。编码器主要负责从原始输入图像中提取语义特征，其过程可以理解为通过多层非线性变换，将原本分辨率较高但语义信息较弱的表示，逐步转化为分辨率降低但语义信息更集中的特征表示。通常情况下，编码器由卷积层、归一化层、激活函数以及下采样模块等组成，有时候也会结合一些特征增强结构，共同完成特征提取过程。解码器的作用则是对编码器输出的特征进行逐步恢复，将低分辨率的语义特征重新映射回高分辨率的像素空间，从而实现对输入图像的细粒度预测。和编码器更偏向语义信息提取不同，解码器在设计时会更加关注空间信息的恢复，比如边界细节的还原以及多尺度特征之间的融合。一般来说，解码器会包含上采样模块、特征融合网络、卷积上采样模块，以及相应的归一化和激活函数，最终通过输出层得到分割预测结果。




图 2.1 经典编解码网络

卷积层是编码器的基础组成单元，其主要作用是提取图像的局部空间特征。通过局部感受野与权值共享机制，卷积操作能够有效捕捉图像中的边缘、纹理及结构信息。对于第 l 层卷积，其计算过程为式 2.1 所示：

$$F_l = W_l * F_{l-1} + b_l \quad (2.1)$$

其中， F_l 表示第 l 层特征， W_l 表示卷积核参数， F_{l-1} 为 $l-1$ 层特征， b_l 为偏置项， $*$ 为卷积运算。在编码器中，卷积核尺寸通常设置为 3×3 或 1×1 ，前者用于提取局部空间特征，后者主要用于通道维度压缩与特征融合。

归一化层主要用于对特征分布进行一定程度的标准化处理，从而在训练过程中缓解梯度消失或梯度爆炸等问题，同时也有助于提升收敛速度。常见的方式包括批归一化和组归一化，不同方法在批量大小或计算资源受限的情况下各有适用场景。至于非线性激活函数，它的作用是为编码器引入非线性表达能力，使模型可以拟合更加复杂的特征关系，常见的有 ReLU、LeakyReLU、SiLU 和 PReLU 等。一般来说，这些激活函数会接在卷积层和归一化层之后，形成一个基本的卷积块组合，这种结构被多数网络模型采用，效果也相对稳定。

下采样是编码器中不可缺少的一步，主要用于降低特征图分辨率，同时扩大感受野并减少计算量，常见做法包括最大池化以及带步长的卷积操作。在一些较深的网络结构中，还会加入残差连接或密集连接，用来缓解训练过程中的困难，让特征传递更顺畅一点。另外，在目标尺度变化比较明显的场景下，有些编码器还会引入多尺度特征提取模块，比如金字塔池化或者空洞卷积。这类结构通常通过多个分支并行提取不同感受野下的特征，在一定程度上增强了模型对整体上下文信息的理解能力。

在解码阶段，上采样模块作为解码器的主要组成部分，承担着逐步恢复特征图空间

分辨率的任务。常用的上采样方式包括双线性插值、转置卷积以及子像素卷积等，其中双线性插值由于不引入额外参数且计算效率较高，被广泛应用于各类分割模型。鉴于编码器在连续下采样过程中不可避免地会损失部分空间细节信息，解码器通常通过特征融合机制，将编码阶段的浅层特征与解码阶段的上采样特征进行融合，以增强对边缘和细节区域的表达能力。因此，已有研究围绕特征融合策略展开了多种探索，包括单分支结构、特征金字塔结构以及双分支结构等。最终，在解码器末端通常采用 1×1 卷积对特征图进行通道压缩，将高维特征映射至目标类别空间，并依据最大概率原则生成最终的分割结果。

2.3 目标检测方法

目标检测的主要任务是对图像或视频中的目标进行定位与识别，也就是在同一过程中完成类别判断和空间位置回归。和更注重像素级预测的图像分割相比，目标检测更关注的是目标层面的语义信息，以及边界框在几何上的约束关系。早期方法大多依赖人工设计的特征提取器，比如 HOG、SIFT、SURF 等，通过提取颜色、形状、边缘等底层特征来实现目标的分类与定位。不过这类方法在特征表达能力和泛化方面还是有一定局限，一旦场景变复杂，特征提取效果就容易下降。随着深度学习的发展以及硬件性能的提升，目标检测逐渐转向端到端的深度学习框架，在精度、速度以及适应不同场景的能力上都有改善，因此在自动驾驶障碍物检测、安防监控等场景中被广泛采用。

根据主要目标检测模型结构的主要形式，以候选区域生成与分类回归是否分开处理，当前方法可以分为两类。一类是双阶段检测模型，这类方法通常先生成候选区域，再进行分类和位置回归，整体流程更为精细，所以精度也更高，相应地也带来了更大的计算开销；另一类是单阶段检测模型，相反，这类方法则是把定位和分类合并在一个框架中完成，结构更简洁，在速度和实时性方面更有优势，适合对响应时间要求高的场景。

双阶段检测模型的基本流程如图 2.2 所示，一般由骨干网络以及两个主要阶段组成。首先，骨干网络对输入图像进行特征提取，得到多层次的特征表示；接着进入区域建议阶段，通常通过区域建议网络（Region Proposal Network, RPN）在特征图上进行滑动扫描，生成一系列可能包含目标的候选区域，也就是感兴趣区域（Region of Interest, RoI）。在这一阶段，模型主要完成前景与背景的区分，并不会细分具体类别，可以理解为一个初步筛选过程。之后进入第二阶段，这些候选区域会被裁剪并调整到统一尺寸后送入检测头网络，在这里同时完成分类和边界框回归，这个过程一方面会给出每个区域对应的类别标签，另一方面对边界框位置进行进一步调整，使其更贴合真实目标。




图 2.2 双阶段模型

单阶段检测模型将目标检测问题建模为端到端的密集预测任务，不再显式生成候选区域，而是直接在特征图上对目标的类别与空间位置进行联合回归。其核心思想是在一次前向推理过程中同时完成目标定位与分类，从而简化检测流程并提高推理效率，使得该类方法在实时性要求较高的应用场景中具有良好的适用性。典型的单阶段检测网络结构如图 2.3 所示。代表性方法主要包括 SSD 和 YOLO 系列算法。




图 2.3 单阶段模型

SSD^[47]是一种于 2016 年提出的单阶段目标检测方法，其基于卷积神经网络骨干提取特征，并在多尺度特征图上结合不同尺度与长宽比的锚框对目标进行检测，从而有效应对不同尺寸目标的识别需求。该方法能够在整幅图像上同时生成大量候选预测，避免了候选区域生成过程，在保持较好检测精度的同时显著降低了计算复杂度。

YOLO 系列方法采用单一卷积神经网络实现端到端的目标检测，将输入图像划分为若干网格单元，并在每个网格上同时预测边界框坐标及对应的类别概率。相关预测结果由深层卷积特征直接生成，并通过引入多尺度锚框机制增强对不同尺度目标的检测能力。最终检测结果通常借助非极大值抑制进行筛选，以去除冗余和低置信度预测，从而提升检测结果的可靠性。其中，YOLOv1 首次提出了统一的单阶段检测框架，将目标检测任务视为回归问题，通过一次前向传播即可完成边界框位置与类别预测，具备较高的实时

性能。随后，YOLOv3 引入多尺度预测机制，在三种不同尺度的特征图上同时进行边界框回归与分类，显著增强了对小目标和尺度变化目标的检测能力。此后，YOLO 系列模型在网络结构设计、训练策略与优化方法等方面不断演进，持续推动单阶段目标检测技术的发展。表 2.1 对 YOLO 系列模型的主要特征与演化过程进行了系统总结。

表 2.1 YOLO 系列总结

版本	创新方法	优化技术	训练策略	损失函数
YOLO1 ^[48]	简化的 CNN 骨干网络，基本边界框预测	随机梯度下降，非极大值抑制	几何变换，色调抖动	MSE
YOLO2	DarkNet-19 骨干网络，K-means 聚类用于锚框优化	带动量的 SGD，超参数调优，Adam 优化器	微调，预训练权重	SSE
YOLO3 ^[49]	DarkNet-53，多尺度检测，残差连接	非极大值抑制，阈值处理，多尺度目标检测	Mix-up，数据增强，噪声	CIoU/DIoU
YOLO4 ^[50]	CSPDarkNet-5，马赛克数据增强	广义 IoU，焦点损失，动态量化	迁移学习，知识蒸馏	CIoU
YOLO5	CSPNet，动态锚框优化轻量级架构，	训练后量化，滤波器剪枝，低秩近似	Mosaic，CutMix	CIoU
YOLO6 ^[51]	PANet CSPDarkNet53	IoU 损失，置信度阈值处理，多尺度融合	对抗训练，领域特定的数据增强	CIoU/DFL
YOLO7 ^[52]	EfficientRep 骨干网络，动态标签分配	神经架构搜索(NAS)，量化，梯度裁剪	微调对抗补丁检测	CIoU
YOLO8 ^[53]	路径聚合网络	动量和 Adam 优化器	对抗训练数据增强	CIoU/DFL
YOLO9 ^[54]	多级辅助特征提取	GELAN 模块，资源受限系统的深度监督	微调，领域特定的数据增强	L1 Loss
YOLO10 ^[55]	轻量级分类头和分离的空间与通道变换	下采样阶段通过分离空间与通道变换提高效率	无 NMS 训练，双重标签分配	Coord loss confidence loss
YOLO11 ^[56]	C3k2 块，使用 C2P SA 增强空间注意力	量化，随机梯度下降	微调，Mix-up，自适应梯度裁剪	IoU based loss
YOLO12 ^[57]	主干网络引入区域注意力模块，并引入了残差高效层聚合网络	Flash Attention，卷积实现注意力	Mosai、Mixup 和复制粘贴增强等	IoU based loss

除上述以经典卷积为架构的算法之外，基于 Transformer 架构的目标检测模型以其高精度和鲁棒性逐渐变为目标检测的新范式。DETR 是 Facebook AI Research 的 Carion 等人于 2020 年提出的首个基于 Transformer 的端到端目标检测模型，该模型消除了非极大值抑制这一步骤，直接利用位置编码和匈牙利匹配算法实现预测标签与真实标签的一对一匹配，避免了经典的经典目标检测框架中的重复检测问题。在后续的研究中，研究者们从不同角度对 DETR 模型进行改进，如 Deformable DETR、Dynamic DETR、DINO、RT-DETR、MS-DETR 等，表 2.2 对 DETR 系列模型进行了总结。

表 2.2 基于 Transformer 的目标检测模型汇总

模型	创新方法	技术优势	局限性
DETR ^[58]	基于 Transformer 架构，采用位置编码和匈牙利匹配算法直接预测	避免了重复检测，端到端的训练，全局建模	训练收敛慢，对细粒度特征不敏感，小目标检测性能差
Deformable DETR ^[59]	引入可变形卷积和可变形注意力机制，迭代边界框优化	动态调整卷积核的位置，增强特征提取能力，减少冗余计算，收敛快	模型结构更复杂，要求高质量数据，计算成本高
Dynamic DETR ^[60]	引入动态查询机制和基于 ROI 的动态注意力	以从粗到细的方式专注于感兴趣的区域，降低学习难度，更快收敛	模型参数更多，结构更复杂，对超参数的敏感性增加，以来大规模数据集
DAB DETR ^[61]	添加可学习的动态锚点框，利用宽度和高度信息来调制位置注意力图	改善收敛慢问题，定位更准确，减少训练时间	依赖复杂的多层 Transformer 结构，对计算资源需求较高
DN DETR ^[62]	采用了一种噪声引导查询，学习去除这些噪声干扰	加速模型收敛并改善检测精度和鲁棒性，小目标检测能力增强	对超参数更为敏感，动态适应性不足
DINO ^[63]	引入了对比方式进行去噪训练，在训练过程中动态调整锚框的位置和大小，多尺度融合	模型训练的收敛速度加快，对不同尺度目标的检测性能增强	结构更加复杂，计算成本较高，推理速度较慢，实时性差
DA DETR ^[64]	设计 CTBlender 混合器实现有效的特征对齐和跨域知识转移	减少参数依赖，适应性和检测精度更高	训练依赖对抗学习且不稳定，计算成本高，实时性差

续表 2.2 基于 Transformer 的目标检测模型汇总

模型	创新方法	技术优势	局限性
Lite DETR ^[65]	用高效编码器交错的方式更新高级和低级特征，减少检测头的计算量，引入关键感知变形注意力	小目标的检测性能增强，计算量和计算需求降低，泛化能力强	实时推理能力差，跨模态特征融合受限
RT DETR ^[66]	设计高效混合编码器和 CCFM 模块融合多尺度特征，提出不确定性最小化查询选择	高精度、高准确率，推理速度稳定，适用场景灵活	编码器设计复杂，增实现难度高，计算资源需求高，细粒度的精度不足
MS DETR ^[67]	采用混合一对一和一对多监督并调整解码器结构	更好地捕获复杂场景中的小目标和重叠目标，提供更多高质量的预测框	混合监督增加训练时间和计算复杂度，需精细调参

综合以上内容，传统目标检测依赖手工特征和多阶段处理且存在计算效率低、泛化能力弱等问题，难以应对复杂场景。深度学习方法通过端到端架构实现了突破。两阶段算法检测精度高，但速度较慢；单阶段算法则通过简化流程显著提升实时性，但小目标检测能力不足；而基于 Transformer 模型通过全局特征提取提高精度，但大多数模型仍需解决训练耗时和计算成本问题。但在上述模型中，都假定在检测过程中所有要检测的类别都是存在的，这导致了两个问题，一是图像可能包含来自未知类别的物体，目标检测器应该对其进行分类；二是当这些未知的信息变得可用时，模型应该能够增量地学习新的类，而不会忘记学习过的类。开放世界目标检测(Open World Object Detection, OWOD)的概念适合于针对未知场景下的物体识别。这种方法侧重于检测已知和未知的类，同时增量地学习已识别的未知类，充分考虑了现实应用中的未知性，这在自动驾驶领域场景下的应用最为直观。图 2.4 展示了 OWOD 问题的总体框架。




图 2.4 开放世界目标检测总体框架

聂晖等人深入探讨了开放世界的定义和现有工作，涵盖开集学习、零样本学习、小样本学习、长尾学习、增量学习等 5 个开放维度，分析了每个维度的核心挑战^[68]。在开放世界物体识别和检测方面，Joseph 等人提出了一种基于 RPN 的未知类别自动标注方法，用于识别图像中可能属于未知类别的目标区域^[69]。Wang 等人利用多个数据源和异构标签空间的图像通过图像和文本空间的对齐进行训练，这保证了足够的通用表示信息并通过解耦训练和概率校准进一步促进了新类别的泛化能力^[70]。Cheng 等人提出的 YOLO-World 由一个 YOLO 检测器、一个文本编码器和一个可重参数化的视觉语言路径聚合网络组成，为开放视觉语言检测模型的轻量化提供了新思路^[71]。Li 等人使用多个潜在背景类嵌入和一个可学习的通用背景类别嵌入对背景类进行建模，训练时的类别构成由基础类+通用背景类转变为基础类+潜在背景类+通用背景类，提高模型对基类和未知类的识别精度^[72]。Lin 等人提出的 GenerateU 模型不依赖于任何的预定义信息，将检测问题转变为生成问题，模型不仅能够检测到图形数据中的密集对象，还能自由的生成对象的名称。此模型更接近于真实的开放世界目标检测场景^[73]。

2.4 分割与检测评价指标

对于语义分割任务，采用 mIoU (Mean Intersection over Union) 指标评估模型的精度，该值越大代表模型的分割效果越好，计算方法可用公式 2.2 表示：

$$mIoU = \frac{1}{\kappa + 1} \sum_{i=0}^{\kappa} \frac{T_i}{\sum_{j=0}^{\kappa} P_{ij} + \sum_{j=0}^{\kappa} N_{ji} - T_i} \quad (2.2)$$

其中， κ 表示分割类别， $\kappa + 1$ 表示加上背景类， i 表示当前类别， T_i 表示正确预测为类别 i 的像素数， P_{ij} 表示实际为类别 j 但预测为类别 i 的像素数， N_{ji} 表示实际为类别 i 但预测为类别 j 的像素数。

参数量 (Parameters, Para) 是模型中可训练参数的总数，直接影响模型的存储需求和内存占用。

每 10 亿次浮点运算数 (Giga Floating-point Operations Per Second, GFLOPs) 是模型在进行一次前向传播时的浮点运算数量，直接影响设备能耗和推理速度

帧率 (Frames Per Second, FPS) 表示模型每秒钟能够处理的图片数量，作为模型的检测速度评价指标，帧率值越高模型检测速度越快。

在目标检测任务的性能评估过程中，通常会涉及多种评价指标，其中较为关键的指标包括准确率 (Precision)、召回率 (Recall)、平均精度 (Average Precision, AP) 以及

平均精度均值（Mean Average Precision, mAP）。

Precision 用于衡量模型预测结果的可信程度。当准确率较高时，说明模型判定为正样本的结果中，真正样本所占比例较大，计算方式如公式 2.3 所示。

$$Precision = \frac{TP}{TP + FP} \quad (2.3)$$

Recall 主要用于评估模型对目标缺陷检测的完整程度。较高的召回率表明模型能够识别出大部分真实存在的缺陷样本，计算方法如公式 2.4。

$$Recall = \frac{TP}{TP + FN} \quad (2.4)$$

TP 代表正确预测为正类的样本数量、FP 为错误预测为正类的样本数量，FN 为未被正确预测为正类的样本数量。

在多目标检测任务中，AP 是常用的综合评估指标之一。该指标可以理解为在不同召回率条件下检测精度的平均值，并通常针对某一特定类别进行评价。AP 通过计算精确率—召回率曲线（precision-recall curve）下的面积来反映模型性能，其计算方法如式 2.5 所示。为了进一步衡量模型在所有类别上的整体表现，mAP 作为综合评价指标。mAP 表示所有目标类别 AP 值的平均结果，是对模型整体检测能力的重要度量。该指标由各类别的 AP 值进行加权平均得到，计算方式如式 2.6 所示。

$$AP = \int_0^1 P(r) dr \quad (2.5)$$

$$mAP = \frac{1}{K} \sum_{i=1}^K AP_i \quad (2.6)$$

为了评估模型在不同尺度目标上的性能，AP 按照检测目标的大小分为像素小目标 (APS)、中目标 (APM) 和大目标 (APL)。除此之外，设置不同的 IoU 值将 AP 值划分为 mAP₅₀、mAP₇₅、mAP_{50:95} 等。

2.5 本章小结

本章围绕与本文研究相关的理论，展开细致论述。首先介绍深度学习的基本网络架构构成，为理解本文所采用的视觉感知模型奠定基础。其次，详细论述了图像分割方法的原理，为轨道区域分割算法的设计提供依据。随后，围绕目标检测方法展开综述，从算法框架与技术特点、存在的不足方面分析了主流检测方法，为轨道交通场景障碍物检测研究提供方法参考。在此基础上，介绍了图像分割与目标检测任务中常用的评价指标，用于对在实验部分进行可对比性评估。

第三章 融合多尺度特征与多通道注意力的轻量化轨道分割方法

列车视角下的轨道环境场景一般开放环境，但是列控系统所要关注的重点是轨道区域，为了避免列车在运行中将场景中的组成物体统一判定为障碍物，从而导致的误检。本章针对铁路场景下轨道区域识别任务，提出一种轻量化轨道分割网络 LiteRailSegNet (Lightweight Rail Segmentation Network)，该方法将轨道识别问题转化为像素级语义分割任务，采用基于编码器—解码器架构的轻量化全卷积网络实现。整体网络设计兼顾模型效率与分割精度，编码器部分采用多尺度特征提取模块，以有效捕捉轨道区域在不同感受野下的视觉特征，同时结合多尺度边缘上采样的特征增强策略，逐步恢复空间细节信息；解码器部分则通过利用多种尺度的特征和通道与空间双注意力机制，最终实现精确的轨道区域分割。本章内容将围绕网络整体架构展开系统阐述，依次详细介绍网络总体设计、编码器结构、多尺度边缘感知的特征增强机制以及解码器结构。

3.1 分割网络架构

本文所提出的 LiteRailSegNet 网络架构如图 3.1 所示，网络整体遵循编码器—解码器架构，集成了轻量化编码网络、多尺度边缘上采样特征增强网络和解码网络，通过以上模块使得模型能以高分割速度和精度实现轨道区域识别，达到良好的平衡效果。

在编码器部分，网络首先采用初级特征提取块快速降低输入图像分辨率，可以在保证信息的同时减少后续特征尺寸。随后，为了获取多尺度特征，编码器部分采用逐步下采样法提取深层特征，整个编码器部分通过轻量化设计，在降低参数量的同时有效提高了特征提取速，保障了实时性能；在特征融合方面，本文设计了一个多尺度边缘上采样特征增强网络，提升了特征提取后的融合能力，有助于保留轨道区域的边缘细节；解码器部分则不同于传统的全卷积解码网络，而是采用一种对称的多通道特征解码器，这种方法通过使用对称卷积解码结构并融合多注意力机制，保留好关键层级的特征细节，进而能更好的恢复原始特征图，从而提高分割精度；最后，网络通过使用一个结构简单分割头，将解码器输出的特征转换为目标类别所对应的最终的分割结果，完成归带区域端到端的识别。




图 3.1 所提 LiteRailSegNet 网络架构

3.2 轻量化编码网络

本文所提出的轻量化编码网络借鉴 ResNet 网络的基本单元，并通过逐层下采样获取多尺度特征，同时，结合多尺度边缘上采样特征增强网络，增强对目标区域的感知能力，提升复杂场景下的分割精度。

首先，在编码第一阶段，由于属于底层网络，通道数较少，所以标准卷积更高效，同时参数规模与部分卷积相当，因此利用初级特征提取块获取浅层特征，如图 3.2 所示，通过两个 3×3 卷积，获取浅层语义特征。在这里，我选择以 PReLU 作为激活函数，由于 PReLU 允许部分负值通过，提升了信息保留能力，有利于提取更丰富的特征，提升小目标、边缘等细粒度特征的分割效果。有研究表明，PReLU 激活函数在轻量级分割任务上优于传统的 ReLU 激活函数。单个初级提取块可以用公式 3.1 描述为：

$$F_l = PReLU(BN(Conv3(C \times W_i^l \times H_i^l))) \quad (3.1)$$

其中， F_l 表示初级特征， $PReLU$ 是激活函数， $Conv3$ 表示批归一化，表示 3×3 卷积， C 是通道数， W_i^l 是特征图宽度， H_i^l 是特征图高度。




图 3.2 初级特征提取块

对于编码的第二阶段，本文参考 ResNet18 的基本卷积单元，构建了由 5 个基本卷积单元组成的网络层，逐步降低特征分辨率并增加通道数，使得网络具有丰富的语义信息和较强的多尺度特征提取能力。每一层通过部分卷积(Partial Convolution, PConv)获取深层特征，PConv 通过同时减少冗余计算和内存访问，可以更有效地提取空间特征^[34]。其只在输入通道的一部分上应用常规卷积进行空间特征提取，并保持其余通道不变，但是为了充分利用特征图的其余通道信息，在 PConv 之后增加一个逐点卷积(PWConv)，通过两个卷积块之后，将输出特征与原始特征通过残差连接缓解梯度消失问题。在经过多层下采样后，特征图尺寸会变为原始的 1/4, 1/8, 1/16, 1/32, 1/64。最后，对于获取到的特征利用所提出的多尺度边缘上采样特征增强模块（Multi-scale Edge Upsampling Module, MEUM）进行多尺度特征融合，并增强边缘信息，提高编码器特征提取的精度和鲁棒性。本文的基本卷积单元图 3.3 所示。




图 3.3 基本卷积单元

3.3 多尺度边缘上采样特征增强网络

在轨道分割任务中，光照变化、遮挡、轨道磨损等复杂因素的影响可能导致分割结果出现不稳定性。因此特征提取模块的设计对模型的整体性能具有决定性作用。传统的特征提取方法通过增加网络深度来获取更精细的特征，但会导致大量计算开销、部分特

征表达能力不足、边缘信息易丢失以及特征融合不充分的问题。针对上述问题，本文提出多尺度边缘上采样特征增强网络(Multi-scale Edge Upsampling Module, MEUM)，该网络由上采样和多尺度特征增强模块构成，旨在通过多尺度特征融合、边缘增强和多路径信息流的设计，强化高频信息，提升模型获取轨道信息的能力。

MEUM 模块通过多尺度特征融合和边缘增强机制，提升了特征提取能力和边界信息获取能力，其架构如图 3.4 所示。该模块由上采样和多尺度边缘增强构成，利用 1×1 卷积进行通道降维，减少计算开销并对边缘信息进行通道间融合，使得 MEUM 能够在保持分割精度的同时，具备更高的推理速度，适用于实时轨道检测任务。

MEUM 首先对输入特征进行放大，解决特征图中细节特征边缘缺失的问题，提高模型捕捉物体边界的能力。在上采样后利用通道降维降低计算复杂度并在特征空间中进行边缘信息增强和多尺度特征融合，通过多级池化和逐级边缘增强，有效捕获不同尺度下的特征信息，强化高频细节。其计算过程如公式 3.2 所示。

$$F = \text{MEEM}(\text{Upsample}(X))$$

$$\text{MEEM}(X) = \phi(BN(\text{Conv1}(\text{Concat}(X_m, X_{eh}^1, \dots, X_{eh}^N)))) \quad (3.2)$$

其中， $\text{MEEM}(\cdot)$ 表示多尺度边缘增强网络， $\text{Upsample}(\cdot)$ 表示上采样， x 是输入特征， ϕ 是 Sigmoid 函数， BN 表示批归一化， Conv1 表示 1×1 卷积， Concat 表示特征拼接， F 是输出特征， x_m 是中间特征， x_{eh}^N 是增强特征。




图 3.4 MEUM 网络

3.4 多通道注意力解码网络

解码器的作用是提取编码器得到的特征，传统解码器通常仅通过单一层次的特征进行上采样和反卷积操作实现特征融合，这种方法解码器结构简单，但也存在明显的不足。其中，会显著丢失特征的细节信息和语义信息利用不足，同时缺乏对特征通道和空间维度的针对性优化，导致分割精度不足。

为了解决上述问题，本文提出一种新的多通道注意力解码网络(Multichannel Attention Decoding Network, MADN)，如图 3.5 所示。




图 3.5 多通道注意力解码网络

首先，将编码第二阶段中第四层特征 X_F 直接作为通道 1 的输入特征，该层特征语义层次较高，包含丰富的全局上下文信息，有利于提升网络对目标整体结构的理解能力。其次，将编码第二阶段中的第二层特征 M_F 和第三层特征 L_F 分别引入不同扩张率的扩张卷积捕捉得到不同尺度信息作为通道 2 和通道 3 的输入特征，通过设置差异化的膨胀率，在保持特征图空间分辨率一致的前提下，使各分支分别侧重于中尺度与较大尺度特征建模，从而有效增强网络对局部细节及远距离依赖关系的感知能力，利用通道注意力学习 M_F 和 L_F 不同通道之间的重要性并进行融合，从而使得模型更能关注目标区域的特征。进一步地，把经过 MEUM 处理后的第五层特征 T_F 作为通道 4 的输入特征，利用增强的多尺度特征信息和边缘信息。最后，将这 4 个通道的特征进行相加融合，利用空间注

注意力增强特征之间关联，得到最终的解码结果。在获得解码特征之后，采用一个简单分割头实现像素级类别预测。这一阶段的可用公式 3.3 表达：

$$F^{(i)} = f(X_i), i \in \{1, 2, 3, 4\}$$

$$f(X_i) = \begin{cases} \text{Conv3}(X_F) & i = 1 \\ \text{CA}(M_F) & i = 2 \\ \text{CA}(L_F) & i = 3 \\ \text{Conv3}(T_F) & i = 4 \end{cases} \quad (3.3)$$

$$O = \text{SA}((f(X_1) \otimes (1 + A_F)) \oplus (f(X_4) \otimes (1 - A_F)))$$

其中， $f(X_i)$ 为各个输入通道的中间特征， Conv3 为 3×3 卷积， CA 为通道注意力， SA 为空间注意力， O 为输出， A_F 为注意力权重，是通过一个沿水平方向和一个沿垂直方向的卷积来建模空间依赖关系，并经过 Sigmoid 函数归一化，得到两个方向的注意力响应，最后将二者相加获取的。

3.5 实验分析

3.5.1 实验设置与数据集

在实验中，采用高性能计算服务器进行模型训练，具体配置如表 3.1 所示。

表 3.1 实验设置

软硬件名称	版本型号
CPU	Intel Platinum 8633C 32
GPU	Nvidia 4090 D
操作系统	Ubuntu22.04
编程语言	Python3.7
深度学习框架	Pytorch1.13
优化器	Adam
初始学习率	0.0005
权重衰减系数	0.0001
衰减方法	cos
迭代次数	200
批次大小	16
输入尺寸	512

同时，由于轨道区域在图像中的比例小、边界模糊、光照变化显著以及背景复杂等问题，传统的交叉熵损失(Cross-Entropy Loss)容易受到类别不均衡的影响，导致模型更倾向于学习背景特征，而忽视轨道区域。为此，本文设计了一种基于类别分布的自适应损失函数，通过动态调整难例挖掘(Online Hard Example Mining, OHEM)和焦点损失(Focal Loss)的权重，使模型能够更好地适应类别不平衡和难分类样本问题，以增强模型对轨道区域的学习能力。

OHEM 是一种动态难例挖掘方法，旨在针对难分类样本进行重点学习，从而提高模型的判别能力。其核心思想是在计算损失时，仅选取损失值较高的样本进行反向传播，而忽略容易分类的样本。在本文中，OHEM 用于筛选误分类率高的轨道像素，提高模型对轨道区域的关注度。OHEM 的数学表达如公式 3.4:

$$L_{OHEM} = \frac{1}{N} \sum_{i \in \mathcal{H}} L_i \quad (3.4)$$

$$L_i = L(y, \hat{y}) = - \sum_{i=1}^c y_i \log(\hat{y}_i)$$

其中， N 为被选中的样本数量， $\mathcal{H}$ 为损失值较高的样本集合， L_i 表示样本 i 的交叉熵损失， y 是真值标签概率， $\hat{y}$ 是预测正确的概率， c 是类别数量， y_i 是第 i 个类别的概率， $\hat{y}_i$ 是模型预测第 i 个类别的概率。

Focal Loss 是一种改进的交叉熵损失，旨在解决类别不均衡问题。其主要思想是对难分类样本赋予更高权重，而对易分类样本降低权重贡献，考虑到由于轨道像素的数量远少于背景像素，普通交叉熵会使模型倾向于学习背景特征，而 Focal Loss 能有效提升轨道像素的学习权重，避免轨道区域被忽略。Focal Loss 数学表达式如公式 3.5:

$$L_{Focal} = - \frac{1}{N} \sum_{c=0}^{C-1} \sum_{i=1}^N p_i(c) (1 - \hat{p}_i(c))^\gamma \log(\hat{p}_i(c)) \quad (3.5)$$

其中， N 是像素数量， C 是类别数量， $p_i(c)$ 是真值， $\hat{p}_i(c)$ 是预测值， γ 是平衡矫正因子。

尽管 OHEM 可以动态筛选难例样本，但其仅基于损失值进行筛选，未能有效解决类别不均衡问题。相反，Focal Loss 通过调整损失权重，使模型更关注轨道区域，但在训练过程中仍然受到大量背景像素的影响。二者结合后，能够同时提升难例样本学习能力与类别均衡性，其优势包括：1、增强轨道区域的学习权重；2、提高轨道边界识别能力；3、降低计算成本，提高收敛速度。为了防止在训练中背景的样本数量远远多于轨道类别，导致模型倾向于预测背景类，通过基于类别的自适应方法动态调整 OHEM 和 Focal Loss 的权重，使它们的贡献更加平衡，避免某一损失主导训练过程。综合考虑 OHEM 与 Focal Loss 的协同作用，其组合损失函数可以表示为公式 3.6:

$$L_{total} = \alpha L_{OHEM} + \beta L_{Focal} \quad (3.6)$$

其中, α 和 β 为自适应权重因子, 用于平衡两种损失对优化目标的影响。

数据集的构建以及图像质量, 会在很大程度上影响模型性能以及实验结论的可靠性, 如果训练数据质量不合格, 会导致模型在训练阶段难以稳定收敛, 在测试和评估时的泛化性能表现也会受到影响。考虑到轨道交通场景本身较为复杂, 目标类型多样, 同时还存在光照、天气等环境变化, 本文在数据准备过程中更关注样本的多样性问题, 标签的准确性, 以及整体数据分布是否相对一致, 防止出现橄榄球效应, 从而让模型能够更充分地学习列车运行环境中的特征。

在实验过程中, 本文使用了轨道交通领域的公开数据集以及自建空轨数据集来开展研究。公开数据集提供了本领域中常用的规范的样本, 有助于对所提方法进行对比验证, 也便于评估其通用性; 而自建数据集则更贴近实际运行场景, 围绕轨道区域分割和前向障碍物检测任务进行针对性采集与标注, 在一定程度上弥补了公开数据在特定场景和目标类型上的不足。通过这样的数据组织方式, 为后续模型训练、性能评估以及方法有效性的验证提供了较为可靠的数据支撑。

(1) Railsem19 数据集

Railsem19 数据集^[76]总共提供 8500 张图像, 这些图像是以铁路车辆的第一视角拍摄的, 能够全面覆盖列车运行前向场景中的真实信息, 并且该数据集提供了各种任务所需的特定注释, 包括列车、轨道、缓冲站等轨道交通中基础对象的分类, 以及针对分割任务专用的 mask 掩膜标注, 因此可以用于训练基于机器视觉任务的铁路轨道检测的相关研究。为了使得数据集适配本文所提出的分割模型, 本文对该数据集进行了初步的筛选处理, 去除了有轨电车部分, 只留下包含铁轨标签的有效数据, 最终筛选出 6479 张图像, 涵盖了雾、雨、雪等各类天气情况, 以及遮挡、光照变化等多种复杂场景, 在此基础上, 本文将训练集与测试集的比例划分为 8:2。

(2) UAV-RS 数据集

UAV-RS 数据集是本文收集整理的, 为一种基于无人机航拍视角下的轨道图像, 共包含 500 张图像, 能够较全面地反映空中视角下的轨道结构特征。该视角区别于传统的地面或车载采集方式, 旨在验证所提方法的泛化性能。为适应轨道分割任务的需求, 数据集中提供了两类精细标注, 一类为轨道内部区域标注 (Inside), 用于描述轨道所占空间范围; 另一类为轨道线标注 (Lines), 用于精确刻画轨道边缘线条。该数据集的旨在拓展轨道分割研究的应用场景, 使模型能够在无人机视角下实现对轨道结构的高精度识

别与分割，从而为轨道安全检测与巡检任务提供更具实际意义的数据支持。数据集划分比例与前述划分比例保持一致，按 8:2 的比例分为训练集与测试集。

(3) MTSD 数据集

MTSD 为本文联合课题组成员构建的轨道图像分割数据集，其图像数据采集于兴国永磁磁浮空轨线路现场，采用工业相机获取，共计 2260 张高分辨率图像，涵盖了直轨、弯轨等多种典型轨道场景。数据集与前述实验按 8:2 比例划分为训练集与测试集，并通过 LabelMe 工具进行逐像素精细人工标注，标注过程耗时巨大，体现出数据集的研究价值。值得指出的是，MTSD 是目前首个面向磁浮空轨轨道场景的图像分割研究数据集，填补了该细分领域的研究空白。为增强模型的鲁棒性与泛化能力，训练阶段引入了随机裁剪、翻转等图像增强策略，有效缓解了小样本数据带来的过拟合风险。图 3.6 展现了数据的采集设备和采集及处理过程。




图 3.6 MTSD 数据采集与处理

以上介绍的数据集用于本文开展轨道区域提取的研究，列出了数据集中具有代表性场景的部分内容，如图 3.7 所示。



图 3.7 部分用于分割数据

3.5.2 铁路场景实验

在 RailSem19 数据集上的一系列实验结果表明，本文方法在精度与效率之间取得了更好的平衡。为了使评估结果更加全面，本文选取了 9 种具有代表性的对比方法，这些模型基本覆盖了当前语义分割领域的三类典型技术路线。第一类是以 U-Net、DeepLabv3+和 PSPNet 为代表的传统高精度模型；第二类是基于 Transformer 的模型，SegFormer、Mask2Former 和 ViT，这类方法在分割任务中也展现出不错的效果；第三类则是以 BiSeNetv2、MobileNetv2 和 Fast-SCNN 为代表的轻量化模型，这类方法主要面向实时应用场景，结构设计上更注重计算开销与运行效率。通过这样的分层对比方式，可以从多个角度衡量本文方法的性能并进行验证。

在所设定的输入分辨率条件下，表 3.2 给出了各模型在 RailSem19 数据集上的对比结果。从 mIoU 指标来看，本文方法取得了 86.07% 的 mIoU，在所对比的方法中表现为最优效果，超越高精度分割模型。在推理效率方面，本文方法在相同条件下实现了 117.8FPS，单帧约 8.5ms 的推理速度，相较于同类型轻量化模型 Fast-SCNN 提升约 59.4%，同时计算复杂度保持在约 5.2GFLOPs 的水平。尽管本文模型的参数量高于 Fast-SCNN，但在参数规模适度增加的情况下，换来了更明显的精度提升，这也从侧面反映出所采用结构设计在精度与效率之间取得了较为合理的平衡。与 BiSeNetv2 等双分支结构相比，本文方法在保持较高推理速度的同时，实现了更优的分割精度；而与精度相近的 DeepLabv3+相比，推理速度提升显著。

进一步分析表明，性能提升主要来源于三个方面的共同作用：第一，轻量特征编码网络中引入的 PConv 卷积优化提升了 GPU 计算利用率，减少了一些不必要的计算开销；第二，多尺度边缘上采样特征增强网络在仅增加少量参数的前提下，对分割精度带来了

明显改善；第三，多通道注意力解码网络对特征进行了进一步整合，使模型在整体预测时更加稳定，准确率也随之有所提升。

表 3.2 Railsem19 模型性能对比

Model	mIoU	GFLOPs	Para(M)	FPS(帧/秒)	Time(ms)
U-Net	79.98	203.0	28.9	29.4	34.0
DeepLabv3+	85.97	254.0	60.2	30.9	32.3
PSPNet	82.06	179.0	46.6	43.5	22.9
SegFormer	83.92	74.6	81.9	22.8	43.9
Mask2Former	84.35	375.0	212.0	22.2	45.0
ViT	77.29	142.0	443.0	32.2	31.1
BiseNetv2	81.03	12.3	14.7	105.9	9.5
MobileNetv2	82.12	39.3	9.48	115.2	8.7
Fast-SCNN	81.11	3.7	1.40	73.9	13.5
LiteRailSegNet	86.07	5.2	5.29	117.8	8.5

为了更直观地展示模型在不同轨道结构下的分割能力，本文选取了多种具有代表性的方法在测试集上进行可视化展示，结果如图 3.8 所示。其中，第 1 行为 LiteRailSegNet 的分割结果，第 2 至第 4 行分别对应 DeepLabv3+、SegFormer 和 Fast-SCNN 的结果，第 5 行为人工标注的真值。场景涵盖了常见的单轨直线、单轨曲线、双轨直线以及双轨曲线四种轨道形式。

从整体结果来看，在单轨直线和双轨直线这类相对简单的场景中，各方法基本都能够识别出轨道区域，不过在边界表现上还是能看出细微的差别。LiteRailSegNet 在轨道边缘处的结果更连续，轮廓也更清晰，其它方法在边界位置会出现模糊、不完整，甚至有少量误分类的情况。这一表现与引入的 MEUM 网络有关，该模块通过融合多尺度特征，并对边缘信息进行强化处理，在一定程度上弥补了下采样过程中细节信息的损失。

当场景变为单轨曲线或双轨曲线时，轨道形态更加复杂，在具有一定的曲率之后，对模型的表达能力提出了更高要求。在这些情况下，对比方法容易出现边缘断裂，或者将轨道之外的背景误判为轨道区域，而 LiteRailSegNet 整体上能够保持较完整的轨道结构。这主要归因于 MADN 网络的解码设计，利用多种特征再结合通道注意力与空间注意力机制，使与轨道相关的信息得到更充分的恢复，从而在复杂场景下表现得更稳定。




图 3.8 Railsem19 数据集分割效果

注：(a): LiteRailSegNet; (b): DeepLabv3+; (c): SegFormer; (d): Fast-SCNN; (e): Ground-Truth

3.5.3 无人机视角实验

为验证所提方法在无人机视角轨道场景中的分割效果，本文选取实验一中的部分模型，在 UAV-RS 数据集上开展对比实验，并分别从 **Inside**（轨道内部区域）和 **Line**（轨道线）两个子任务对模型性能进行评估，分别用 **R.IoU** 和 **L.IoU** 表示内部区域和轨道线的分割精度，结果如表 3.3 所示。

在 **Inside** 分割任务中，本文方法的表现相对更好，**mIoU** 达到 93.14%，**R.IoU** 为 90.05%，相比表现最好的对比模型 MobileNetv2 的 87.53% **mIoU** 提升约 5.61 个百分点。从结果来看，本文方法在刻画轨道内部区域的整体形状以及边界位置时更加准确。在难度更高的 **Line** 分割任务中，各模型的 **mIoU** 普遍偏低，这也反映出轨道线条这类细粒度结构对模型提出了更高要求。但本文方法仍然取得了较好的结果，**mIoU** 为 69.84%，**L.IoU** 达到 65.45%，高于次优模型 SegFormer 的 64.88%。这印证了本方法在处理复杂场景和细节目标时具备更好的适应能力。

从两个子任务的整体表现可以看出，本文方法在保证区域分割效果的同时，对轨道

线条等细粒度目标也有更好的识别能力。这一结果与所设计的 MEUM 与 MADN 模块有关，两者在特征增强与融合过程中形成了有效的联合，使模型整体表现优于多种语义分割方法，也说明本方法在无人机视角下的轨道感知任务中具有一定的应用价值。

表 3.3 UAV-RS 双任务性能对比

Type Model	Inside		Line	
	mIoU	R.IoU	mIoU	L.IoU
Deeplabv3+	82.48	88.82	60.89	59.91
PSPNet	86.94	88.82	59.36	41.66
FastSCNN	86.73	89.03	62.58	60.71
MobileNetv2	87.53	88.74	58.58	56.95
Segformer	83.56	88.22	67.36	64.88
Mask2Former	79.73	89.45	62.39	59.26
LiteRailSegNet	93.14	90.05	69.84	65.45

3.5.4 自建空轨数据集实验

为进一步验证模型在实际应用场景中的泛化能力，本文在自建的 MTSD 数据集上对所提方法进行了可视化分析，结果如图 3.9 所示。实验样本涵盖了弯轨与直轨两种典型轨道形态，同时也包含室内、室外以及列车内部向外观测等不同成像条件。

从图 3.9 可以看出，LiteRailSegNet 在多种环境下都能够较为稳定地识别出轨道区域，整体分割效果也呈现连续性。在远距离场景中，局部区域会出现轻微的边界不够清晰的情况，不过整体识别结果仍然准确，没有出现明显偏差。综合来看，模型在 MTSD 数据集上取得了 95.56% 的平均交并比，这也在一定程度上说明该方法在实际轨道交通环境中具备较好的应用可行性。



图 3.9 MTSD 分割效果图

注：(f)：弯轨；(g)：直轨

3.5.5 消融实验

为验证设计的模块对模型性能的作用,本文在 Railsem19 数据集上进行了消融实验,通过测试基准模型,分别引入多尺度边缘上采样特征增强模块(MEUM)、多通道注意力模块(MADN),以及将两个模块(MEUM-MADN)联合后模型的实验结果。如表 3.4 所示。

表 3.4 消融实验

模块	影响因素			评价指标				
	PConv	MEUM	MADN	mIoU	Para	GFLOPs	FPS	Time
A				81.87	7.88	8.77	76.5	13.1
B	√			80.65	5.04	5.11	118.3	8.3
C	√	√		85.18	5.17	5.23	117.1	8.5
D	√		√	85.81	5.13	5.18	117.3	8.5
E	√	√	√	86.07	5.29	5.2	117.8	8.5

注: √表示使用了对应的模块

基准模型基于标准卷积构建,其余模型则统一替换为 PConv 结构,在尽量保证不损失性能的前提下,探索模型在轻量化后的表现。从实验结果来看,即使采用了更轻量的 PConv 结构,MEUM 和 MADN 的引入在准确度上仍然带来了明显的提升。加入 MEUM 后, mIoU 由 81.87%提升至 85.18%,说明多尺度边缘上采样特征在轨道结构建模上起到了正向作用;在此基础上引入 MADN 后, mIoU 进一步提高到 85.81%,可以看出多通道结构结合注意力机制在特征解码阶段是有帮助的。当两个模块同时使用时,模型取得了最好的结果, mIoU 达到 86.07%,相比基准模型提升了 4.2 个百分点。在性能提升的同时,模型的参数量由 7.88M 降低至 5.29M,计算量从 8.77GFLOPs 下降到约 5.2 GFLOPs,推理速度提升至 117.8FPS,对应单帧约 8.5ms。这样的变化说明,模型在保持较好分割效果的同时,也兼顾了计算开销。

此外, PConv 的引入使得 MEUM、MADN 以及 MEUM—MADN 几种模型的参数量基本都控制在约 5.2M 左右,计算量也维持在约 5.2 GFLOPs,推理速度提升到 117FPS,相比基准模型的 76.5FPS 有很大的提升,推理时间则缩短至 8.5ms。虽然 PConv 本身并不会直接带来精度上的提升,但可以降低计算复杂度和提高运行效率,为模型在实际部署中提供了良好的支持。

因此,所设计的模型通过 PConv 在降低计算开销方面的作用,联合 MEUM 和 MADN

在提升模型分割精度方面的作用实现了轻量化与高效性之间的良好平衡，为各种轨道场景下的应用提供了可行的解决方案。

3.6 本章小结

针对列车动态运行环境下轨道感知难度大、且车载计算资源有限导致轨道分割精度与实时性难以兼顾的问题，提出了一种嵌入与智能轨道交通避障系统的轻量级轨道分割网络 LiteRailSegNet，通过引入部分卷积构建轻量化特征提取网络，在仅 5.29M 参数和 5.2G FLOPs 的有限资源下，实现了分割精度与推理速度之间的平衡。多尺度边缘上采样特征增强模块通过融合多尺度上下文信息，显著提升了模型对轨道边界特征的感知能力；而多通道注意力解码网络则通过通道与空间双重注意力机制，强化了多层特征的语义关联，所提模块可以广泛应用于自动驾驶、轨道交通领域，为智能交通提供强有力的技术支持。

为全面评估模型性能，本文在多个数据集上进行了实验验证。结果表明，LiteRailSegNet 在 Railsem19 数据集上取得了超越当前主流分割模型的效果；在无人机航拍数据集下实现了 90.05% 的区域交并比和 65.45% 的线交并比，在自建 MTSD 数据集上也达到 95.56% 的 mIoU，展现出良好的泛化能力与场景适应性。而消融实验进一步验证了各模块的有效性，特别是多尺度边缘上采样模块对边界保持和多通道注意力机制对细节处理上的作用得以直观体现。

本章研究通过构建轻量化的轨道分割网络，为列车运行环境感知中的像素级轨道识别任务提供了有效技术方案，并为轨道交通场景的视觉结构化理解奠定了理论基础。实验结果表明，所提出的 LiteRailSegNet 算法在车载视觉场景中能够实现对轨道区域的准确且稳定识别，在保证较高分割精度的前提下，该方法显著提升了模型的处理效率，满足列车实时视觉感知系统在实际应用中的需求。

第四章 基于分割先验和预训练特征的障碍物检测方法

在第三章中，本文对列车运行轨道的准确快速分割方法开展了研究，实现了轨道区域的像素级语义理解，轨道区域分割的意义在于为后续障碍物检测提供确切的检测范围。基于此，为更好的提升列车运行过程中的安全避障能力，本章在轨道分割结果的基础上开展障碍物入侵检测研究。本章研究内容与轨道分割任务后续任务形成有效补充，两者通过协同能够实现对轨道区域及其周边潜在侵限目标的感知与检测。通过轨道区域分割实现检测范围的划分，然后在划分基础上对区域内及周边存在的障碍物进行识别与预警。本章将对障碍物检测的整体框架、检测方法以及实验效果展开论述，从而构建更加完善的轨道交通环境感知方案。

4.1 检测网络架构

本文是依据轨道分割—障碍物检测这一技术路线，整体流程如图 4.1 所示。




图 4.1 分割检测流程

首先由 LiteRailSegNet 提取到轨道区域，再由检测模型识别障碍物，所提检测方法的网络架构如图 4.2 所示。本文所提出的 RT-ODFormer(Rail Transit Obstacle Detection Former)网络同样遵循编码器—解码器架构，整体框架由特征提取主干网络、两级特征传播网络以及基于 Transformer 的检测头解码网络三部分组成。首先，在特征提取阶段，采用基于 DINOv3 预训练的 ConvNeXt 网络作为视觉编码 Backbone。该网络在大规模视觉数据上进行预训练，具备较强的低层纹理建模能力和高层语义表达能力。主干网络在不同下采样阶段输出三层多尺度特征图，用于覆盖近距离大型障碍物与远距离小尺度目标的检测。其次，在多尺度编码阶段，引入两级特征聚焦传播网络对来自 backbone 的多

尺度特征进行统一通道映射与跨尺度交互融合，该网络作为 Neck 部分，输出三个尺度一致、通道统一的多尺度特征图，为后续全局建模提供稳定输入。最后，采用 DFINE Transformer 解码器作为 Head，将多尺度特征展平并进行拼接，构建全局记忆特征序列，并加入位置编码以保持空间结构信息，通过多层解码器结构进行迭代更新。最终，通过并行的分类分支与边界框回归分支对每个查询向量进行预测，输出固定数量的候选目标。




图 4.2 RT-ODFormer 网络框架

4.2 基于预训练的特征编码网络

在轨道交通障碍物检测任务中，视觉特征表示的质量会直接影响后续检测网络对场景的理解效果。不过在目前使用的方法中，由于标注成本较高、场景变化又比较多，大规模且分布均匀的标注数据难以获得，这也使得传统依赖监督学习的特征预训练方法在泛化和稳定性方面存在一定局限。针对这一情况，本文引入自监督视觉特征学习机制，并构建一种基于 DINOv3 (Distillation with No Labels v3) [74] 自监督预训练的特征编码网络作为障碍物检测模型的主干结构。该主干网络以 ConvNeXt [75] 结构为基础，通过大规模无标注数据进行自监督预训练，从而获得适应性更强的视觉特征表示。在结构上，去除了原有的分类头，仅保留特征提取部分，在输出阶段组织类标记与 patch-level 特征，使其在特征形式上与 Vision Transformer 保持一致。

在本文的网络训练任务中，主干网络的参数始终保持冻结，仅用于生成多尺度特征，为后续 Neck 部分提供输入。这种方式在不明显增加计算负担的前提下，有助于提升模型在降低计算开销方面的能力和检测稳定性。

4.2.1 自监督视觉特征建模

自监督学习（Self-Supervised Learning, SSL）是一种能够从无标签的数据集中学习特征表示的方法，通过利用数据集自身蕴含的结构信息，能够达到在不依赖人工标注就获得具有初步的特征识别能力。与传统监督学习相比，此类方法在轨道交通障碍物检测这一类任务中表现出一些实际优点。一方面，轨道交通场景中的异常障碍物类型较多，而且数据分布往往不均衡，尽管本文选用的数据集弥补了这一劣势，但单纯依赖人工标注数据会受到一定限制。自监督学习可以借助大量未标注数据，从中发掘出潜在结构信息，进而能在一定程度上缓解对大规模标注数据的依赖，大大降低了标注成本。另一方面，自监督方法更加关注图像在结构和语义层面的稳定特征，因此在不同光照条件、复杂天气以及多视角变化下，通常能保持更好的适应能力。

本文选取 DINOv3 作为自监督预训练方法，用于对 ConvNeXt 主干网络进行初始化。DINOv3 基于教师—学生（Teacher—Student）自蒸馏框架，如图 4.3 所示，与传统蒸馏方法依赖人工标注或外部教师模型的蒸馏方式不同，自蒸馏是通过在同一网络结构内部构建教师—学生模型，实现无监督条件下的知识迁移。教师网络由学生网络参数的指数滑动平均（EMA）更新得到，用于提供稳定的目标分布；学生网络通过反向传播不断逼近教师网络输出，从而逐步学习到语义一致的特征表示。整个过程不依赖类别标签，而是通过约束同一图像在不同视角下的特征保持一致，实现对高层语义信息的建模。

DINOv3 作为一种通用视觉基础模型，在不进行额外微调的情况下，也能取得较好的整体表现，甚至在一些情况下优于以往的自监督、弱监督方法以及部分专用模型。同时，它生成的特征表示相对更细致，可以直接用于目标检测等下游任务，并在效果上有一定提升。另外，DINOv3 以开源模型形式提供了多种规模的预训练权重，使其在不同计算资源条件下都具备一定的适用性，无论是资源受限环境还是对性能要求较高的场景，都能够进行相应部署，适合于车载嵌入式设备的直接迁移。




图 4.3 DINOv3 自蒸馏框架

设输入图像为 x 通过随机数据裁剪、颜色扰动、马赛克模糊等增强策略生成的多个不同类型的数据，用式 4.1 表示为：

$$\{x^{(1)}, x^{(2)}, \dots, x^{(K)}\} \quad (4.1)$$

教师网络与学生网络分别对这些视角编码，得到对应的特征向量，如式 4.2 所示：

$$\begin{aligned} z_t^{(i)} &= f_t(x^{(i)}) \\ z_s^{(j)} &= f_s(x^{(j)}) \end{aligned} \quad (4.2)$$

其中， $z_t^{(i)}$ 和 $z_s^{(j)}$ 分别表示教师网络与学生网络的编码特征， $f_t(\cdot)$ 和 $f_s(\cdot)$ 分别为教师与学生网络的特征映射函数。

为了增强特征分布的判别性，引入带温度参数的 softmax 操作，如式 4.3 所示：

$$\begin{aligned} p_t^{(i)} &= \text{softmax}\left(\frac{z_t^{(i)}}{\tau_t}\right) \\ p_s^{(j)} &= \text{softmax}\left(\frac{z_s^{(j)}}{\tau_s}\right) \end{aligned} \quad (4.3)$$

其中， $\tau_t < \tau_s$ ，用于控制教师输出分布的尖锐程度，提供更加明确的学习目标， $p_t^{(i)}$ 和 $p_s^{(j)}$ 分别表示教师网络与学生网络的输出特征

与早期的自监督方法相比，DINOv3 在特征学习时更侧重于关注整体结构和语义上的一致性，而不是只停留在局部纹理或者简单的对比关系上，这种差异在一些结构特征明显的视觉场景中更为直观。对于轨道交通场景来说，由于轨道本身就具有较强的几何连续性特征，同时障碍物会出现嵌入在背景之中的情形，上述特性使得 DINOv3 更容易捕捉到长距离的空间依赖关系，并形成对整体场景的理解。因此，在类似轨道这种动态环境下进行障碍物检测时，它能够提供更稳定的先验特征支持。

4.2.2 特征编码主干网络

上一节介绍了本文采用的 DINOv3 自监督预训练策略，而主干网络就是需要将输入图像映射为多尺度、语义一致性的特征表示，以支撑后续障碍物检测模块的既能实现全局建模也能做到精确定位。基于此，本文选用了 ConvNeXt 作为特征编码主干网络，并在 DINOv3 预训练权重的基础上再做进一步调整。

从结构上看，ConvNeXt 是一种即保持了卷积神经网络计算优势，同时又借鉴了 Vision Transformer 设计思想的现代卷积网络。其设计思想是在于以纯卷积结构逼近 Transformer 的特征建模能力，同时避免自注意力机制带来的高计算复杂度。

如图 4.4 所示，ConvNeXt 主干整体采用分阶段的层级结构来实现特征提取过程。网络由一个初始下采样层（Stem）和四个特征阶段（StageA 到 StageD）组成，输入图像

首先会通过一个步长为 4 的卷积操作完成初始特征的降采样，随后在各阶段中交替进行特征提取与分辨率压缩，从而形成多尺度特征表示。设输入图像为 $X \in \mathbb{R}^{H \times W \times 3}$ ，通过 ConvNeXt 编码后，输出多尺度特征映射为 $\{P_1, P_2, P_3, P_4\}$ 。




图 4.4 ConvNeXt 结构图

在每一个阶段中，网络均堆叠若干个 ConvNeXt Block，以逐步增强特征的语义表达能力。随着网络深度的增加，特征图的空间分辨率逐级减小，而通道维度逐级增大，使得高层特征更加关注全局结构与语义信息。该层级化设计使网络能够同时保留局部细节与全局上下文信息，适用于目标尺度变化显著的轨道交通场景。其中各阶段特征的空间分辨率与通道数逐级变化如表 4.1 所示。

表 4.1 ConvNeXt 各阶段特征

阶段	下采样率	特征维度
A	4	96
B	8	192
C	16	384
D	32	768

在本文模型中，选取 B、C、D 阶段的特征，作为后续多尺度建模的输入，以在空间精度与语义抽象能力之间取得平衡。

ConvNeXt 的基本计算单元为 ConvNeXt Block，其结构如图 4.5 所示。ConvNeXt Block 以原始的 ResNet 为参考，每个 Block 由深度可分离卷积、归一化操作、逐点卷积以及残差连接组成。首先，输入特征通过一个大核深度可分离卷积进行空间建模，以显著扩大感受野并增强对长程结构信息的捕获能力。随后，采用 Layer Normalization 对特征进行归一化处理，以替代传统卷积网络中常用的 Batch Normalization，从而提高在小批量训练和复杂光照条件下的稳定性。在完成空间特征提取后，Block 通过两个逐点卷积对通道维度进行非线性映射与重组，其中引入非线性激活函数以增强模型表达能力。

该通道混合过程在功能上与 Transformer 中的前馈网络相似，但完全基于卷积实现，避免了自注意力机制带来的高计算复杂度。




图 4.5 ConvNeXt Block 结构图

最后，模块采用残差连接将输入特征与变换后的特征进行融合，有效缓解深层网络中的梯度消失问题，并促进特征复用。通过多层 Block 的堆叠，网络能够逐步构建从低层几何结构到高层语义信息的层级化特征表示。单个 Block 的计算过程如式 4.4 所示。

$$Y = X + \mathcal{F}(X) \quad (4.4)$$

$$\mathcal{F}(X) = PWConv(GELU(PWConv(LN(DWConv7(X))))$$

其中， Y 为输出， X 为输入， $\mathcal{F}(\cdot)$ 表示由一系列卷积和归一化操作组成的残差映射函数。具体包括大核深度可分离卷积 DWConv7、归一化 LN、逐点卷积 PWConv 与非线性激活 GELU。

在本文方法中，ConvNeXt 不仅作为特征提取网络承担基础视觉编码功能，同时也是把自监督学到的视觉信息往下游任务里传递的一个中间桥梁。经过 DINOv3 的自监督预训练之后，网络在多视角一致性的约束下，会逐渐学到稳定的语义表达。即使是在对同一图像做不同尺度的裁剪或者其它数据增强后，提取出来的特征在整体上依旧是一致的，这一特性在实际应用场景中具有关键的意义。

通过分阶段的层级化特征编码结构，自监督特征在 ConvNeXt 中逐级传递并不断聚合语义信息。浅层特征主要关注边缘、纹理等局部结构，而随着网络深度的增加，中高层特征逐渐融合场景的全局布局和上下文信息。这种由局部到整体的特征提取过程，使得编码结果在保持空间分辨率信息的同时，具备较强的语义判别能力，既保证了没有完全丢掉空间细节，又让特征具备了更强的语义区分能力，为后续建模提供了基础信息。

轨道交通场景具有显著的结构特征，如轨道区域的线性延伸形态、嵌入关系以及障碍物尺度变化范围大等特点。ConvNeXt 采用的大核深度可分离卷积在扩大感受野的同时保持了卷积结构的空问归纳偏置，有利于捕获轨道的长距离结构信息和整体几何布局。另外，分层的特征建模方式使模型能够在不同尺度上同时处理远距离小目标与近处的大

目标，使得检测模型对目标更为灵活，也更贴合轨道场景里的实际情况。

4.3 两级特征聚焦传播网络

在轨道交通障碍物检测任务中，目标在图像中的远近会影响特征提取的效果，因此远距离小目标与复杂背景对特征表达对模型性能提出了更高的要求。为此，本文在 4.2.2 节中主干网络输出的多层语义特征的基础上，设计了一种两级特征聚焦传播网络（Two-level Feature Focus Propagation Network, TFFP-Net），通过将特征对齐映射和两次聚焦传播，实现对轨道关键区域的有效建模与高质量特征融合。

TFFP-Net 的设计思想不是将特征直接相加或简单的拼接，而是通过两级递进的特征聚焦与层级传播方法，分步强化对轨道区域及障碍物的特征辨识能力，为后续检测头解码提供多种融合后的多尺度特征表示。

如图 4.6 所示，TFFP-Net 接收来自骨干网络的三层特征作为输入，这些特征在语义抽象程度和空间分辨率上存在显著差异。传统特征融合方法往往侧重于不同分辨率之间的信息对齐，忽略了特征在传播过程中的聚焦性与引导性，容易引入冗余背景信息，且对轨道交通场景中纵向结构显著、横向变化受限的特点建模不足。为此，TFFP-Net 引入特征聚焦传播的概念以中间语义层作为空间锚点，在两级结构中引导高、低层特征向关键区域集中传播，从而逐步增强对轨道障碍物的感知能力。TFFP-Net 实现过程如下。




图 4.6 TFFP-Net 网络架构

步骤 1: 通过 1×1 卷积输入投影层 $\phi(\cdot)$, 将主干网络的不同层级的特征 P_i 映射至相同的特征维度 $\tilde{P}_i$, 为后续的信息交互构建统一的特征空间。计算过程如式 4.5 所示:

$$\tilde{P}_i = \phi(P_i), \tilde{P}_i \in \mathbb{R}^{C \times H_i \times W_i} \quad (4.5)$$

步骤 2: 网络进入第一级特征聚焦传播阶段, 该阶段通过特征聚焦模块实现。首先对映射后的 3 层特征进行尺度对齐处理。高分辨率特征通过上采样 $\mathcal{U}$ 补充语义信息, 中分辨率特征保持原尺度作为结构参考, 而低分辨率特征则通过自适应下采样模块 $\mathcal{D}$ 进行压缩, 以在降低分辨率的同时保留关键判别信息。这种非对称的尺度调整方式, 能够避免传统金字塔结构中多次插值导致的语义稀释问题。计算过程如式 4.6 所示:

$$\begin{aligned} \tilde{P}_1 &= \mathcal{U}(\phi(P_1)) \\ \tilde{P}_2 &= \phi(P_2) \\ \tilde{P}_3 &= \mathcal{D}(\phi(P_3)) \end{aligned} \quad (4.6)$$

步骤 3: 在尺度对齐后, 来自不同层级的特征被拼接为 X_{concat} , 通过多分支深度可分离卷积 $DWConv_k$ 对特征进行局部与邻域响应建模, 使网络能够在不同感受野范围内感知轨道区域与潜在障碍物的特征。同时, 引入残差连接以维持原始特征分布的稳定性。通过这一过程, 网络生成了第一级聚焦特征 F_{focus1} , 该特征并不直接作为输出, 而是作为语义传播的核心载体, 分别向高层和低层进行定向传播。计算过程如式 4.7 所示:

$$\begin{aligned} X_{cat}^{(1)} &= [\tilde{P}_1 | \tilde{P}_2 | \tilde{P}_3] \\ M_{dw}^{(1)} &= \sum_{k \in \{3, 5, 7, 9\}} DWConv_k(X_{cat}^{(1)}) \\ X_{agg} &= \phi(\text{ReLU}(\text{BN}(M_{dw}^{(1)}))) \\ F_{focus1} &= \phi(X_{cat} + X_{agg}) \end{aligned} \quad (4.7)$$

步骤 4: 在向高层传播过程中, 聚焦特征经过下采样后与高层特征融合, 其目的是在保持高层语义抽象能力的同时, 引入来自中低层的局部结构与目标细节信息, 从而提升对中远距离障碍物的识别稳定性。在向低层传播过程中, 聚焦特征通过上采样与低层特征融合, 用于在强语义引导下重新校准细粒度特征响应, 减少背景噪声对小目标检测的干扰。计算过程如式 4.8 所示:

$$\begin{aligned} F_{down}^{(1)} &= \text{Conv}_3(\text{AvgPool}(F_{focus1})) \\ P_3^{(1)} &= \text{C2f}([F_{down}^{(1)}, P_3]) \\ \text{C2f}(X) &= \text{Concat}(X_0, \text{Bottleneck}(X_1), \dots, \text{Bottleneck}(X_n)) \\ F_{up}^{(1)} &= \phi(\mathcal{U}(F_{focus1})) \\ P_1^{(1)} &= \text{C2f}([F_{up}^{(1)}, P_1]) \end{aligned} \quad (4.8)$$

步骤 5: 在完成一次完整的聚焦与传播后, 网络进入第二级特征聚焦阶段。该阶段

以第一级传播后的高层、中层与低层特征作为输入，再次执行特征聚焦操作。与第一级不同的是，第二级聚焦更多侧重于语义一致性与跨层信息的精细协调，其作用在于消除首次传播过程中可能产生的语义偏差，并进一步强化关键区域的稳定响应。通过两级递进式聚焦，网络逐步形成层次清晰、语义一致且目标响应集中的特征表示。计算过程如式 4.9 所示：

$$\begin{aligned}
 F_{\text{down}}^{(2)} &= \text{Conv}_3(\text{AvgPool}(F_{\text{focus1}})) \\
 P_3^{(2)} &= \text{C2f}([F_{\text{down}}^{(2)}, P_3]) \\
 \text{C2f}(X) &= \text{Concat}(X_0, \text{Bottleneck}(X_1), \dots, \text{Bottleneck}(X_n)) \\
 F_{\text{up}}^{(2)} &= \phi(\mathcal{U}(F_{\text{focus1}})) \\
 P_1^{(2)} &= \text{C2f}([F_{\text{up}}^{(2)}, P_1])
 \end{aligned} \tag{4.9}$$

经过第二级聚焦传播后的多层特征被输出至解码器。这些特征在空间分辨率上保持层次差异，在语义表达上具备高度一致性，保留了低层的细节感知能力，平衡了中层的语义信息和空间细节，融合了高层的全局上下文信息，从而为轨道交通障碍物检测任务提供更加鲁棒且判别性更强的编码特征。每一层输出特征计算过程为 4.10 所示：

$$\begin{aligned}
 P_3^{\text{out}} &= \text{C2f}([F_{\text{down}}^{(2)}, F_{\text{down}}^{(1)}, P_3^{(1)}]) \\
 P_1^{\text{out}} &= \text{C2f}([F_{\text{up}}^{(2)}, F_{\text{up}}^{(1)}, P_1^{(1)}]) \\
 P_2^{\text{out}} &= F_{\text{focus2}}
 \end{aligned} \tag{4.10}$$

4.4 检测头优化

在获得经自监督预训练与 TFFP-Net 增强后的高质量特征表示后，如何有效建模特征之间的全局关系并完成障碍物的精确定位与分类，是轨道交通障碍物检测任务中的关键问题。基于卷积的检测头通常依赖局部滑窗或锚框机制进行目标预测，其建模方式受限于固定感受野，难以充分利用全局上下文信息。在轨道交通场景中，障碍物往往分布在具有强几何约束的轨道区域内，目标之间及目标与背景之间存在显著的空间关联关系，仅依靠局部特征容易导致误检或漏检。基于此，本文采用 Transformer 架构作为检测头，通过显式的全局关系建模机制，直接在特征层面建立不同空间位置和尺度之间的关联。DFINE Transformer 以查询（Q）为中心，通过跨尺度注意力机制对编码后的特征进行解码，从而将障碍物检测问题转化为一个集合预测的全局建模问题。

DFINE Transformer 检测头以多尺度特征作为输入，采用编码—解码式的 Transformer 架构完成障碍物检测任务。其核心思想是通过一组可学习的查询向量，与输入特征进行多头注意力交互，从而逐步聚合与目标相关的全局信息。

由 4.3 节可知, TFFP-Net 输出的多尺度特征为 $P^{out} = \{P_1^{out}, P_2^{out}, P_3^{out}\}$, DFINE Transformer 首先对各尺度特征进行展平并加入位置编码, 随后作为键 (K) 和值 (V) 输入解码器。在每一层解码器中, 查询向量 Q 通过跨注意力机制与多尺度特征进行交互, 其计算形式为式 4.11:

$$Attention(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = softmax\left(\frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{d}}\right)\mathbf{V} \quad (4.11)$$

其中 K 和 V 分别来自多尺度特征映射, d 为特征维度。通过多层解码迭代, 查询向量逐渐聚焦于潜在障碍物区域, 并在特征空间中形成对目标语义和空间位置的联合表示。

在整个检测框架中, DFINE Transformer 是一个转换中心, 将前面得到的特征表示整理成具体的预测目标结果, 它把原本停留在特征层的信息, 进一步转化为可以直接用于定位和分类的输出。其中的跨尺度注意力机制起到了一个关键的作用, 使不同分辨率的特征不再分别输出结果, 而是被聚集到同一个解码空间中再进行统一处理, 通过这种方式, 不管是远处的小目标, 还是近距离的大目标, 都能在同一套建模架构下被共同分析解码, 这对轨道环境这种尺度变化明显的场景而言, 解码效率的提升是更为合适的。另外, 这种基于查询的解码方式也让整个检测流程变得简便, 它不再依赖密集生成候选框, 也省去了后面的非极大值抑制这类繁琐的筛选步骤, 整体流程更直接, 推理时的开销也更容易控制。

4.5 实验结果分析

4.5.1 实验设置与数据集

表 4.2 实验软硬件参数

软硬件名称	版本型号
CPU	Intel Platinum 8633C 32
GPU	Nvidia 4090 D
操作系统	Ubuntu22.04
CUDA 版本	12.6
编程语言	Python3.11
深度学习框架	Pytorch2.3

续表 4.2 实验软硬件参数

软硬件名称	版本型号
预训练权重	DINOv3_ConvNeXt_Tiny
优化器	Adamw
初始学习率	0.00025
图像大小	640
迭代次数	80
批次大小	8

针对检测任务,由于真实数据难以获取,本文通过收集整理部分具有代表性的数据集作为实验数据。数据集中的部分内容如图 4.7 所示。

(1) SynRailObs 数据集

SynRailObs 数据集^[77]是一个面向铁路障碍物检测任务的高保真合成数据集。作者从网络列车视频中提取 10000 多张背景图像,分辨率为 1280×720 ,并结合 Objects365、PennFudan、DTD 及 Stable Diffusion 生成稀有和难以捕捉的障碍物,这些障碍物在现实世界场景中通常难以获得。合成流程通过 SAM 自动生成前景掩码、按轨道视角与尺度进行透视变换并采用图像和谐技术提高真实感,最终覆盖了行人(persons)、动物(animals)、摩托(motos)、车辆(vehicles)、岩石(rocks)这 5 类障碍物。

论文与作者在 Kaggle 上的发布页面提供了详细的合成流程与样例,便于复现与比较。由于原始数据集极为庞大,本文在研究中采用组合训练的方式,在五类障碍物中各自选择 2000 张图像,组合成一个多目标障碍物数据集,并且按照 8:1:1 的训练比例划分为训练集、验证集和测试集。

(2) Detect-on-Tracks 数据集

Detect-on-Tracks 数据集旨在为计算机视觉模型检测铁路轨道上人员行为提供依据,主要目标是通过提供高质量的带注释图像来提高铁路安全性,这些图像可用于训练模型以实时检测未经授权的人为干预,从而防止事故发生。

数据集包含 3766 张人类在铁路轨道上的行为图片,分辨率为 1080×1080 。每幅图像都带有边界框注释,标记人类的存在及其在铁路轨道上的行为。注释以 txt 格式提供,并带有详细的类标签,这些图像共有 4 个类别:轨道、站立、坐、睡觉。该数据集非常适合训练和评估铁路安全检测模型、物体检测和实时监控系统的研究检测模型。在训练中,8:1:1 的训练比例划分为训练集、验证集和测试集。




图 4.7 障碍物检测数据

4.5.2 多目标障碍物实验

在 SynRailObs 轨道交通障碍物数据集上，本文提出的 RT-ODFormer 在各类别检测任务中均表现出优异性能。如表 4.3 所示，本文所提的模型在 *animals*、*motos*、*persons*、*rocks* 以及 *vehicles* 五类目标上的平均检测精度分别达到 0.83、0.91、0.93、0.72 和 0.94，整体性能优于当前主流的高精度 Transformer 检测模型，两阶段检测模型以及单阶段检测方法，体现了模型在复杂轨道场景中较强障碍物识别能力和良好的泛化性能。

对于 *animals* 与 *rocks* 这类具有形态多变、边界纹理复杂以及与轨道背景相似度高的目标，是轨道交通领域障碍物检测中的重点常见类别。相比于传统基于卷积的检测器，RT-ODFormer 通过 DINOv3 预训练的 ConvNeXt 主干网络，为模型提供了更加稳定的特征表达，使模型能够更直接地捕捉轨道表面细节以及石块边沿轮廓的局部结构信息。同时，Transformer 解码器具备全局建模能力，能够捕获长距离空间中的上下文关系，从而更准确地区分轨道背景与障碍物目标。通过全局信息与局部特征的协同作用，使模型在复杂纹理环境下依然能够保持较高的识别精度。

在 *persons* 与 *vehicles* 等结构相对固定且尺度较大的类别上，RT-ODFormer 同样取得领先或并列领先的检测结果，说明所提出结构在增强小目标检测能力的同时，并未牺牲对大目标的定位精度。相比原始 DETR 在 *persons* 与 *rocks* 类别上显著偏低的检测性能，可以看出，本文通过特征聚焦传播与查询优化机制，有效缓解了原始 Transformer 检测框架对小目标建模不足及收敛缓慢的问题。与 YOLO 系列方法相比，RT-ODFormer 在难检测类别上的性能提升更加明显，表明基于查询的端到端检测机制在类别均衡性和复杂背景抑制方面具有一定优势。

在引入轨道区域分割先验后，模型整体检测性能得到一定提升。其中，*animals* 类别检测精度提升至 0.85，*persons* 类别提升至 0.94，*rocks* 类别提升至 0.75，提升效果相对明显；而 *motos* 与 *vehicles* 类别检测结果变化较小。轨道区域分割先验能够在一定程度

上提升障碍物检测性能。

综合来看, RT-ODFormer 在不同类别上的出色表现以及在难检测类别上的明显优势, 直接验证了所提出网络在轨道交通障碍物检测任务中的有效性与性能优势。实验结果表明, 本文所提的检测方法, 能够更好地解决轨道交通场景中因为目标尺度变化大、背景嵌入且安全要求高的实际应用需求。

表 4.3 SynRailObs 数据集类别比较

models	mAP ₅₀	animals	motos	persons	rocks	vehicles
DFINE	0.76	0.85	0.92	0.72	0.90	
DINO	0.77	0.82	0.87	0.68	0.88	
DETR_r18	0.72	0.68	0.55	0.36	0.82	
RTDETRv2	0.81	0.89	0.92	0.73	0.94	
Faster RCNN	0.83	0.88	0.89	0.67	0.92	
Libra RCNN	0.84	0.88	0.90	0.69	0.93	
Dyna RCNN	0.83	0.89	0.92	0.71	0.93	
YOLOv11s	0.82	0.88	0.91	0.70	0.89	
YOLOv10s	0.80	0.87	0.88	0.69	0.88	
YOLOX	0.79	0.84	0.86	0.66	0.87	
RT-ODFormer	0.83	0.91	0.93	0.72	0.94	
seg-RT-ODFormer	0.85	0.91	0.94	0.75	0.94	

为进一步验证所提出 RT-ODFormer 在轨道交通障碍物检测任务中的性能, 本文通过使用热力图可视化了模型对障碍物的检测结果, 如图 4.8 所示。针对 animals、motos、persons、rocks 以及 vehicles 五类目标, 每一类分别选取 3 幅图像样本, 对模型输出响应区域进行可视化展示。通过对比原始图像与对应热力图中的目标分布, 可以直观地观察模型在不同类别目标上的关注区域及其空间分布情况。

从整体表现来看, RT-ODFormer 在 5 类目标上均能够定位到准确的检测区域, 热力分布与真实目标位置高度吻合, 而背景区域的响应则相对较弱。这说明模型在复杂轨道

场景中具备良好得目标区域聚焦能力，能够有效抑制轨道结构、轨枕木板以及远处背景干扰所带来干扰。同时，热力图呈现出平滑且连续地响应形态，反映出模型在空间表达上具有较强的一致性。在不管是远距离小目标，还是近距离大尺度目标的识别中，模型均能以高置信度识别出各类目标，这与解码器对长距离依赖关系的建模能力呈正相关。

分类别看，在 **animals** 和 **rocks** 类别中，由于目标形态变化大且尺度较小，热力图显示，注意力主要集中于动物的主体轮廓区域，而对周围环境的响应较低，这说明 TFFP-Net 有效增强了模型对细粒度结构的识别能力，模型在石块边缘区域形成明显高响应区，证明模型能够通过全局语义信息区分背景与其它目标。对于 **persons**、**vehicles** 和 **motos** 结构较为规则且语义特征明显的类别，热力图呈现出较为完整的目标响应区域，覆盖目标主体区域，虽然偶尔出现延伸至背景区域，但也能正确识别出轨道区域内的目标。




图 4.8 检测结果热力图

为进一步验证模型对不同尺度目标的检测能力，本文统计了对小目标、中目标与大目标三类目标检测性能，实验结果如表 4.4 所示。

表 4.4 不同目标检测精度

目标尺度	AP ₅₀	AP _{50:95}	AR
小目标	0.65	0.46	0.84
中目标	0.76	0.54	0.87
大目标	0.84	0.57	0.92

从实验结果可以看出，随着目标尺度增大，模型在 AP₅₀、AP_{50:95} 以及 AR(Average Recall)指标上均呈现逐步提升趋势。其中，大目标检测 AP₅₀ 达到 84%，AR 达到 92%，说明模型对于大目标具有较好的检测与定位能力；对于小目标检测，模型仍取得了 65% 的 AP₅₀ 与 84% 的 AR，表明所提方法能够较好地完成远距离小目标的感知与识别。

由于轨道交通场景中的障碍物通常以远距离目标形式出现，在图像中呈现小尺度与弱纹理特征，因此检测难度较高。本文所设计的特征传播结构能够增强不同层级特征之间的信息交互，并结合 Transformer 全局建模能力，提高模型对小目标区域的特征表达能力，从而增强对远距离障碍物的检测效果。此外，小目标召回率达到 84%，说明模型能够有效降低远距离障碍物漏检风险。在轨道交通避障安全场景中，提前感知远距离障碍物对于保障列车运行安全具有重要意义，因此模型较高的小目标召回能力验证了其在轨道交通安全感知任务中的应用潜力。

4.5.3 行人行为检测实验

在 Detect-on-Tracks 数据集上的实验结果如表 4.5 所示。从整体检测精度来看，RT-ODFormer 在该数据集上取得 62.5% 的 mAP₅₀ 和 43.9% 的 mAP_{50:95}，在所有对比方法中均达到最佳性能。与当前较为先进的实时 Transformer 检测模型 RT-DETRv2 相比，本文模型在 mAP₅₀ 指标上提升 6.1 个百分点，mAP_{50:95} 指标上提升 5.6 个百分点；而相比原始的 DINOv3 检测模型，RT-ODFormer 在 mAP₅₀ 指标上提升了 6.7 个百分点，与传统的两阶段检测方法相比，本文模型同样表现出绝对优势，各个指标均高于对比方法。对比试验结果表明，在复杂铁路场景下，本文方法能够更加准确地识别不同姿态的人员目标。

表 4.5 Detection On Tracks 性能比较

模型名称	评价指标				
	mAP ₅₀	mAP _{50:95}	Para	GFLOPs	FPS
YOLOv12-s	43.0	31.8	9.23	21.41	212.9
YOLOv12-n	37.3	25.8	2.56	6.54	224.5
YOLOv11-s	42.2	22.3	9.42	21.5	215.5
YOLOv11-n	32.6	21.5	2.59	6.33	248.4
YOLOv10-s	31.4	21.5	7.22	21.6	223.7
YOLOv10-n	31.0	21.0	2.28	6.76	213.5
SSD	29.6	14.3	24.28	88.11	112.1
Faster RCNN	53.7	33.6	41.63	217	115.2
Dyna RCNN	58.3	35.6	41.37	208	112.4
Libra RCNN	55.5	33.3	41.63	217	112.0
DFINE	51.5	34.4	3.72	7.12	125.4
DINOV3	55.8	38.0	47.56	274	106.0
DETR	51.2	37.7	28.83	49.95	117.6
RT-DETRv2	56.4	38.3	19.88	59.87	127.3
RT-ODFormer	62.5	43.9	4.51	80.91	157.4
seg-RT-ODFormer	63.1	45.3	4.51	80.91	152.1

从模型复杂度角度来看，RT-ODFormer 的训练参数量仅为 4.51M，低于传统的大型检测器，体现出良好的轻量化特性，同时计算量为 80.91 GFLOPs，经过分析发现主要来自于检测头，尽管与轻量级 YOLO 系列模型相比，在推理速度和计算量上略有不足，但在相同实验条件下，YOLO 系列模型的检测精度明显低于本文方法。


在推理速度方面，RT-ODFormer 达到 152.1FPS 的检测速度，快于传统两阶段检测方法，也优于所对比的 Transformer 类，虽然 YOLO 系列模型在 FPS 上高于本文方法，但其精度的不足是实际应用中的局限。因此，从综合性能来看，RT-ODFormer 在精度与推理速度之间取得了更加均衡的表现，更适合应用于铁路车载计算设备中。

而在引入轨道区域分割先验后，模型检测性能得到进一步提升。seg-RT-ODFormer 在 mAP₅₀ 指标上由 62.5%提升至 63.1%，在 mAP_{50:95} 指标上由提升至 45.3%，说明轨道区

域先验不仅提升了目标检测准确率，同时增强了模型对目标位置的定位精度，虽然模型推理速度下降，但仍能够满足轨道交通场景下实时视觉感知任务的部署需求。

为了能直接感受所提方法在测试集上预测结果，本文通过可视化方法展示了几种具有代表性模型的检测结果，如图 4.9 所示。RT-ODFormer 在三种行人行为上的均能呈现高精度的预测，均高于 0.8 的置信度，在识别上满足检测需求；RT-DETRv2 和 YOLO12s 的检测结果略低于本方法；相比于高精度的 Dyna RCNN 在 sleeping 和 sitting 行为上呈现出了误分类的效果，这种情况在交通安全领域中是需要避免的；在 SSD 中，模型的检测框过于繁杂，且无法分辨出具体的检测范围。

由可视化结果来看，本文所提方法更适合于实际应用，未出现误检漏检的情况，且各种行为类别能高准确度检出，这对于轨道交通中最常见的行人入侵检测是友好的。得益于本文的高效特征编码网络和特征聚焦传播网络，为全局的特征提取和建模提供了稳定输入，而解码检测头没有采用非极大值抑制这种后处理，不需要过滤掉多余的检测框，通过三者的联合，节省了特征提取过程中的计算资源消耗，同时既保障了精度，又提高了检测效率。






图 4.9 行人行为检测结果

4.6 本章小结

本章围绕轨道交通场景中障碍物种类多样、目标尺度变化明显以及实时检测需求高等问题，提出了一种基于预训练特征的轨道交通障碍物检测模型 RT-ODFormer。该模型整体采用编码器—解码器式检测框架，结合卷积网络的局部特征提取能力方面的优势与 Transformer 在全局关系建模方面的能力，实现对轨道环境中多类别障碍物的高效识别。

在结构设计上，首先引入基于 DINOv3 自监督预训练的 ConvNeXt 作为主干网络，用于提取多层次视觉特征，以获得丰富的特征编码信息；随后，通过 TTFP-Net 模块对不同层级特征进行统一的通道映射与特征信息聚焦传播，从而提升模型对多尺度目标的辨别能力；在解码阶段，采用 DFINE Transformer 解码器对融合后的多尺度特征进行全局建模，并通过查询驱动机制完成目标类别预测与边界框回归，有效提升了复杂轨道场景下障碍物检测的精度。

本文在轨道障碍物检测数据集 SynRailObs 以及 Detect-on-Tracks 数据集上开展了对比实验，并与多种主流目标检测方法进行了全面分析，以评估所提 RT-ODFormer 模型的检测性能。实验结果表明，RT-ODFormer 在多个评价指标上均取得了较好的检测效果，在保持较高检测精度的同时，仍具备较低的模型复杂度与较快的推理速度，能够满足轨道交通场景下实时视觉感知任务的部署需求。此外，针对不同尺度目标的实验结果表明，模型在远距离小目标检测任务中仍保持较高的召回率，验证了所提方法在复杂轨道环境下对潜在障碍物的感知能力。通过热力图与检测结果可视化分析可以看出，模型能够有效关注轨道区域内关键目标区域，降低复杂背景信息带来的干扰，提高对轨道区域障碍物的定位与识别准确性。进一步地，多数据集实验结果表明，所提出方法在不同场景与数据分布条件下均具有较好的泛化能力与环境适应能力，能够为轨道交通避障安全感知系统提供可靠的视觉感知支持。

综合来看，本文提出的 RT-ODFormer 能够在检测精度、计算效率和模型规模之间取得较为理想的平衡，为轨道交通环境感知与安全监测系统中的障碍物检测任务提供了一种可行的技术方案。

第五章 总结与展望

5.1 全文工作总结

轨道交通作为国家交通基础设施的重要组成部分，作为社会发展的大动脉，其健康发展关乎国计民生的方方面面，尤其是在安全性方面。传统依赖人工巡检或基于经典算法的环境感知方式已难以满足安全性与智能化发展的需求。在列车自动驾驶与智慧运维不断推进的背景下，构建具备高精度与快速响应的环境感知系统，已成为本领域技术更新的重要方向。围绕这一目标，本文以轨道场景为研究对象，基于深度学习方法全面开展了轨道场景分割与障碍物检测的视觉感知技术研究，从模型结构设计、特征表达增强到复杂环境适应能力等多个方面进行了探索。通过构建面向实际工况的数据集与实验方法，对所提方法在常见的列车运行场景中的有效性进行了验证。取得的主要贡献及研究成果如下：

（1）本文针对车载计算资源受限条件下轨道分割方法精度与实时性难以兼顾的难题，提出了一种融合多尺度特征与多通道注意力的轻量级轨道分割模型 LiteRailSegNet。该模型基于部分卷积构建高效的特征提取网络，在保证特征表达能力的同时，有效降低了参数规模与计算复杂度；设计了多尺度边缘上采样特征增强模块，通过结合上采样操作与多尺度特征融合的边缘强化机制，缓解了轨道边界信息在特征传递过程中的损失问题，从而提升了模型对轨道区域关键结构的感知与表达能力；构建了多通道注意力解码网络以融合多层特征和通道-空间双重注意力，增强对细节纹理与高层语义的建模能力，提升分割方法的精度与推理效率。实验结果表明，所提方法在多个公开数据集与自建数据集上均取得了较好的分割精度与实时性能，并在模型复杂度与推理速度之间实现了较好的平衡，满足轨道交通场景下车载实时部署需求。

（2）针对轨道交通场景中障碍物目标尺度变化明显、小目标占比高以及实时检测需求较高的问题，本文提出了一种基于分割先验和预训练特征的轨道交通障碍物检测方法 RT-ODFormer。所提方法采用编码器—解码器检测框架，由特征提取主干网络、两级特征聚焦传播网络以及 Transformer 解码器三部分组成。在特征提取阶段，引入基于 DINOv3 自监督预训练的 ConvNeXt 主干网络，通过输出多层次特征以获取图像中丰富的语义信息；利用 TTFP-Net 模块对不同尺度特征进行统一通道映射，并实现多尺度信息聚焦传播，提升模型对远近不同尺度目标的感知能力；在解码阶段，通过 DFINE Transformer 解码器对融合传播后的多尺度特征进行全局关系建模，并结合查询驱动机制

实现对候选目标的优化，从而完成目标类别预测与边界框回归。本文进一步构建了基于轨道区域分割先验的障碍物检测流程，通过轨道区域分割结果对检测区域进行约束，减少非轨道区域背景信息干扰。实验结果表明，引入轨道区域先验后，模型的检测性能均取得进一步提升，尤其在小目标、弱纹理目标以及复杂背景场景下表现更加稳定。

5.2 未来研究展望

本文围绕轨道交通系统的避障系统中的视觉感知方法展开研究，针对复杂轨道场景下的轨道区域分割与障碍物检测问题，基于深度学习方法进行了相关模型设计与实验验证，并取得了一定研究成果。然而，由于实际轨道运行环境复杂多变，以及实验条件与数据规模的限制，本文研究仍存在一定不足，后续仍有若干值得进一步深入研究与优化的方向，主要体现在以下几个方面：

(1) 列车在实际运营条件下，环境更为复杂，实际测试当中仍缺乏在超大尺度轨道场景、轨道严重磨损条件下的实验验证，同时本研究只与通用分割模型进行了对比，未与同类任务下最新专用方法在统一基准下的系统性对比。未来研究将致力于复杂环境下的模型自学习，并利用真实运营场景数据进行持续优化，同时完成与专业方法的全面性能评估，实现模型的落地部署与应用，推动轨道交通场景理解的安全系统发展。

(2) 尽管本文提出的 RT-ODFormer 在检测精度与实时性能之间取得了较为理想的平衡，但从整体计算开销来看，仍存在进一步优化的空间。当前模型的计算负担主要集中在检测头部分，尤其是基于 Transformer 的解码模块，在多层注意力计算与特征交互过程中引入了较高的计算复杂度。针对这一问题，后续研究可从检测头的轻量化设计入手，对解码结构进行性优化，在尽量保持检测精度的前提下压缩解码器规模、降低计算成本，从而进一步提升模型在车载嵌入式设备中的运行效率与实际部署能力。同时，与分割模型的联合检测中，在部分场景的轨道识别中出现了分割区域偏差，这与模型同时占用计算资源有关，未来可进一步优化模型联合后分割与识别的结果。

(3) 本文的实验数据主要使用相机采集，尽管模型在实验中取得了较好的结果，但单一的视觉传感器在深度信息获取、隧道环境、遮挡场景以及复杂气象条件下的稳定性仍存在一定局限。未来研究将可结合多传感器融合，构建融合激光雷达、毫米波雷达、红外传感器的多传感融合模型，通过多模态的环境感知方法，弥补模型在弱光、雨雪雾天气、夜间环境下的检测性能损失。此外，虽然本文的障碍物检测模型使用预训练特征提取网络能考虑到了未知障碍物，但是与针对开放环境下的直接预测存在区别，仍然达不到真正识别出未知障碍物，在这方面后续可以开展深入研究，使得模型不再依赖于标注数据集。

参考文献

- [1] 中国城市轨道交通协会.城市轨道交通 2024 年度统计和分析报告[R]. 中国城市轨道交通协会信息, 2025(67).
- [2] “红轨”来了! 世界首条永磁磁浮空轨工程试验线竣工[J]. 中国工程咨询, 2022(09): 109.
- [3] 央视网. 云南昆明洛羊镇火车站内发生试验列车撞施工作业人员事故[EB/OL]. (2025-11-27). <https://news.cctv.com/2025/11/27/ARTIKOaLcenkcG2edKLruSQC251127.shtml>.
- [4] Catalano F A, Bruno A, Pisco M, et al. An intrusion detection system based on the optical fiber technology for the protection of railway assets[C]//Proceedings of the XVIII AISEM Annual Conference. Trento, Italy, 2015: 1-4.
- [5] Mane S, Shah S A K. Object tracking and analysis for detecting various situations at level crossings of railway-road[C]//Proceedings of the 2017 International Conference on Computing, Communication, Control and Automation (ICCUBE). Pune, India, 2017: 1-5.
- [6] Liang H, Zhu L, Yu F R, et al. Blockchain-empowered edge intelligence for TACS obstacle detection: System design and performance optimization[J]. IEEE Transactions on Industrial Informatics, 2024, 20(1): 85-95.
- [7] Krizhevsky A, Sutskever I, Hinton G E. ImageNet classification with deep convolutional neural networks[J]. Communications of the ACM, 2017, 60(6): 84-90.
- [8] Wang S Q, Fan Z G. Multi-sensor fusion rolling bearing intelligent fault diagnosis based on VMD and ultra-lightweight GoogLeNet in industrial environments[J]. Digital Signal Processing, 2024, 144: 104345.
- [9] Zhang R, Yao W, Shi Z, et al. Encoding time series as images: A robust and transferable framework for power system DIM identification combining rules and VGGNet[J]. IEEE Transactions on Power Systems, 2023, 38(6): 5781-5793.
- [10] Wu Z, Shen C, Van Den Hengel A. Wider or deeper: Revisiting the ResNet model for visual recognition[J]. Pattern Recognition, 2019, 90: 119-133.
- [11] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J/OL]. arXiv, 2017.
- [12] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16×16 words: Transformers for image recognition at scale[C]//Proceedings of the International Conference on Learning Representations. 2021.
- [13] Liu Z, Lin Y, Cao Y, et al. Swin transformer: Hierarchical vision transformer using shifted windows[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. Piscataway: IEEE Press, 2021: 10012-10022.
- [14] He K, Chen X, Xie S, et al. Masked autoencoders are scalable vision learners[J/OL]. Computing Research Repository, 2022.
- [15] Radford A, Kim J W, Hallacy C, et al. Learning transferable visual models from natural language supervision[C]//Proceedings of the International Conference on Machine Learning. 2021: 8748-8763.
- [16] Ramesh A, Pavlov M, Goh G, et al. Zero-shot text-to-image generation[C]//Proceedings of the International Conference on Machine Learning. 2021: 8821-8831.

-
- [17] Rombach R, Blattmann A, Lorenz D, et al. High-resolution image synthesis with latent diffusion models[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 10684-10695.
 - [18] Long J, Shelhamer E, Darrell T. Fully convolutional networks for semantic segmentation[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2015: 3431-3440.
 - [19] Chen L C, Papandreou G, Kokkinos I, et al. DeepLab: Semantic image segmentation with deep convolutional nets, atrous convolution, and fully connected CRFs[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2018, 40(4): 834-848.
 - [20] Bhange B, Ingale S, Ghode S, et al. Semantic scene segmentation in unstructured environment with modified DeepLabV3+[J]. Pattern Recognition Letters, 2020, 138: 223-229.
 - [21] Yu C, Wang J, Peng C, et al. BiSeNet: Bilateral segmentation network for real-time semantic segmentation[C]//Proceedings of the European Conference on Computer Vision. Cham: Springer International Publishing, 2018: 325-341.
 - [22] Sandler M, Howard A, Zhu M, et al. MobileNetV2: Inverted residuals and linear bottlenecks[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE Press, 2018: 4510-4520.
 - [23] Cheng B, Misra I, Schwing A G, et al. Masked-attention mask transformer for universal image segmentation[J/OL]. arXiv, 2022.
 - [24] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16×16 words: Transformers for image recognition at scale[C]//Proceedings of the International Conference on Learning Representations. 2021.
 - [25] Liu Z, Lin Y, Cao Y, et al. Swin transformer: Hierarchical vision transformer using shifted windows[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. Piscataway: IEEE Press, 2021: 10012-10022.
 - [26] Xie E, Wang W, Yu Z, et al. SegFormer: Simple and efficient design for semantic segmentation with transformers[C]//Advances in Neural Information Processing Systems. 2021, 34: 12077-12090.
 - [27] Zhang G J, Liu J C, Fan Z, et al. A lightweight encoder–decoder network for automatic pavement crack detection[J]. Computer-Aided Civil and Infrastructure Engineering, 2024, 39(12): 1743-1765.
 - [28] Wang Y, Wang L, Hu Y H, et al. RailNet: A segmentation network for railroad detection[J]. IEEE Access, 2019, 7: 143772-143779.
 - [29] Belyaev S, Popov I, Shubnikov V, et al. Railroad semantic segmentation on high-resolution images[C]//Proceedings of the 2020 IEEE 23rd International Conference on Intelligent Transportation Systems. Rhodes: IEEE, 2020: 1-6.
 - [30] Yang H, Li X, Guo Y, et al. Discretization–filtering–reconstruction: Railway detection in images for navigation of inspection UAV[J]. IEEE Transactions on Instrumentation and Measurement, 2022, 71: 1-13.
 - [31] 路通, 余祖俊, 郭保青, 等. 网状多尺度与双向通道注意力的铁路场景语义分割[J]. 交通运输系统工程与信息, 2023, 23(2): 233-241, 299.
 - [32] 郑泽熙, 范楷, 邓晶雪. 基于改进 Mask R-CNN 网络的轨道交通运行环境感知技术应用研究[J]. 铁道运输与经济, 2024, 46(1): 184-191, 198.
 - [33] Zhou L, Chen G, Liu L, et al. Real-time semantic segmentation in traffic scene using cross stage partial-

- based encoder-decoder network[J]. *Engineering Applications of Artificial Intelligence*, 2023, 126: 106901.
- [34] Feng Z, Yang J, Chen Z, et al. LRseg: An efficient railway region extraction method based on lightweight encoder and self-correcting decoder[J]. *Expert Systems with Applications*, 2024, 238: 122386.
- [35] Wei D, Wei X, Tang Q, et al. RTLseg: A novel multi-component inspection network for railway track line based on instance segmentation[J]. *Engineering Applications of Artificial Intelligence*, 2023, 119: 105822.
- [36] 刘朝辉, 杨杰, 陈智超. 基于深度学习的轨道表面异物识别方法[J]. *中国铁道科学*, 2023, 44(3): 23-33.
- [37] Girshick R, Donahue J, Darrell T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[C]//*Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*. 2014: 580-587.
- [38] Ren S, He K, Girshick R, et al. Faster R-CNN: Towards real-time object detection with region proposal networks[J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2017, 39(6): 1137-1149.
- [39] He D, Zou Z, Chen Y, et al. Obstacle detection of rail transit based on deep learning[J]. *Measurement*, 2021, 176: 109241.
- [40] Zhang Z, Chen P, Huang Y, et al. Railway obstacle intrusion warning mechanism integrating YOLO-based detection and risk assessment[J]. *Journal of Industrial Information Integration*, 2024, 38: 100571.
- [41] 王楠, 侯涛, 牛宏侠. 多尺度特征融合的铁轨异物入侵检测研究[J]. *西安交通大学学报*, 2024, 58(9): 139-153.
- [42] Qin Y, He D, Jin Z, et al. An improved deep learning algorithm for obstacle detection in complex rail transit environments[J]. *IEEE Sensors Journal*, 2023, 24(3): 4011-4022.
- [43] Zhang M, He D, Liu Q, et al. LDCD-Net: Lightweight dual-channel detection network for obstacles detection on rail transit[J]. *Signal, Image and Video Processing*, 2025, 19(4): 281.
- [44] 戴鸿辉, 耿晨歌, 刘丹丹, 等. 基于激光雷达的城轨交通障碍物检测算法研究[J]. *铁道科学与工程学报*, 2023, 20(6): 2350-2360.
- [45] Zhu G, Nan Z, Zhang X, et al. High precision rail surface obstacle detection algorithm based on 3D imaging LiDAR[J]. *Optics and Lasers in Engineering*, 2024, 178: 108206.
- [46] Hou L, Yu-wen T, Kai-cheng C, et al. A denoising FPN with transformer R-CNN for tiny object detection[J]. *IEEE Transactions on Geoscience and Remote Sensing*, 2024, 62.
- [47] Chen Z, Guo H, Yang J, et al. Fast vehicle detection algorithm in traffic scene based on improved SSD[J]. *Measurement*, 2022, 201: 111655.
- [48] Redmon J, Divvala S, Girshick R, et al. You only look once: Unified, real-time object detection[C]//*Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*. 2016: 779-788.
- [49] Novak B, Ilic V, Pavkovic B. YOLOv3 algorithm with additional convolutional neural network trained for traffic sign recognition[C]//*Proceedings of the 2020 Zooming Innovation in Consumer Technologies Conference (ZINC)*. 2020.
- [50] Roy A M, Bose R, Bhaduri J. A fast accurate fine-grain object detection model based on YOLOv4 deep neural network[J]. *Neural Computing and Applications*, 2022, 34(5): 3895-3921.
- [51] Li C, Li L, Jiang H, et al. YOLOv6: A single-stage object detection framework for industrial

- applications[J/OL]. arXiv, 2022.
- [52] Wang C Y, Bochkovskiy A, Liao H Y M. YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 7464-7475.
- [53] Rejin V, Sambath M. YOLOv8: A novel object detection algorithm with enhanced performance and robustness[C]//Proceedings of the 2024 International Conference on Advances in Data Engineering and Intelligent Computing Systems (ADICS). 2024: 1-6.
- [54] Muhammad W K, Mohammad S O, Khalid M, et al. Real-time road damage detection using an optimized YOLOv9s-fusion in IoT infrastructure[J]. IEEE Internet of Things Journal, 2025, 12(11): 17649-17660.
- [55] Z Pengchun, Chen H, Guo J, et al. Improved YOLOv10 for high-precision road defect detection[C]//Proceedings of the International Conference on Computer Science and Blockchain. 2024: 79-83.
- [56] H L H, Zhang Y Z, Li L, et al. Research on object detection and recognition in remote sensing images based on YOLOv11[J]. Scientific Reports, 2025, 15(1).
- [57] Tian Y, Ye Q, Doermann D S. YOLOv12: Attention-centric real-time object detectors[J/OL]. arXiv, 2025.
- [58] Carion N, Massa F, Synnaeve G, et al. End-to-end object detection with transformers[C]//Proceedings of the European Conference on Computer Vision. Cham: Springer, 2020: 213-229.
- [59] Zhu X Z, Su W J, Lu L W, et al. Deformable DETR: Deformable transformers for end-to-end object detection[C]//Proceedings of the International Conference on Learning Representations. 2021.
- [60] Dai X Y, Chen Y P, Yang J W, et al. Dynamic DETR: End-to-end object detection with dynamic attention[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. Piscataway: IEEE, 2021: 2968-2977.
- [61] Liu S, Li F, Zhang H, et al. DAB-DETR: Dynamic anchor boxes are better queries for DETR[C]//International Conference on Learning Representations. 2022.
- [62] Li F, Zhang H, Liu S L, et al. DN-DETR: Accelerate DETR training by introducing query denoising[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2022: 13609-13617.
- [63] Zhang H, Li F, Liu S, et al. DINO: DETR with improved denoising anchor boxes for end-to-end object detection[C]//International Conference on Learning Representations. 2023.
- [64] Zhang J Y, Huang J X, Luo Z P, et al. DA-DETR: Domain adaptive detection transformer with information fusion[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2023: 23787-23798.
- [65] Li F, Zeng A L, Liu S L, et al. Lite DETR: An interleaved multi-scale encoder for efficient DETR[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2023: 18558-18567.
- [66] Zhao Y A, Lv W Y, Xu S L, et al. DETRs beat YOLOs on real-time object detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2024: 16965-16974.
- [67] Zhao C Y, Sun Y F, Wang W H, et al. MS-DETR: Efficient DETR training with mixed supervision[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition.

- Piscataway: IEEE, 2024: 17027-17036.
- [68] 聂晖,王瑞平,陈熙霖.开放世界物体识别与检测系统: 现状、挑战与展望[J].计算机研究与发展,2024,61(09):2128-2141.
- [69] Joseph K J, Khan S, Khan F S, et al. Towards open world object detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 5830-5840.
- [70] Wang Z, Li Y, Chen X, et al. Detecting everything in the open world: Towards universal object detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 11433-11443.
- [71] Cheng T, Song L, Ge Y, et al. YOLO-World: Real-time open-vocabulary object detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 16901-16911.
- [72] Li J, Zhang J, Li J, et al. Learning background prompts to discover implicit knowledge for open vocabulary object detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 16678-16687.
- [73] Lin C, Jiang Y, Qu L, et al. Generative region-language pretraining for open-ended object detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 13958-13968.
- [74] Huang S H, et al. Real-time object detection meets DINOv3[J/OL]. Computing Research Repository, 2025.
- [75] Zhuang L, Ma H, Wang C Y, et al. A ConvNet for the 2020s[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 11966-11976.
- [76] Zendel O, Murschitz M, Zeilinger M, et al. RailSem19: A dataset for semantic rail scene understanding[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops. 2019.
- [77] Guo Q, Rambach J. SynRailObs:A synthetic dataset for obstacle detection in railway scenarios[EB/OL]. 2025.

致谢

执笔至此，论文只有五章，但我的人生有数不尽的章节。回首在江西理工大学求学的这一章，能顺利走完远非我一人所能完成，在此以心中的谢意，献给支持与陪伴我走完这段路的人。

首先，最崇高的敬意与感谢献给我的导师，刘鸿恩副教授，您是引我进入智能控制组这个大家庭的领路人。从论文的选题立意、框架搭建，到研究方法的设计、疑难问题的攻坚，直至最终字句的斟酌推敲，每一个环节都倾注着您的心血与智慧。您严谨求实的治学态度、深邃敏锐的学术洞察力，对学生毫无保留的倾囊相授，令我深深折服。在我研究陷入瓶颈时的耐心点拨，在我气馁时的温暖鼓励，都化为我坚持前行的不竭动力。

感谢一路同行的同窗挚友与实验室的兄弟姐妹们。特别感谢我的同门李旭、文凯、宣帅、杨柳以及对我提供帮助的师弟师妹们，我们在无数个日夜里的并肩讨论、相互激励，是这段旅程中最生动的声音，与你们一同奋斗、一同成长的时光，是我青春记忆里最璀璨的篇章。山水一程，三生有幸，愿我们此去前程似锦，再相逢依然如故。

感谢参与论文评审和答辩的各位专家教授。感谢你们在百忙之中拨冗审阅本文并提出宝贵的批评与指导意见，你们的真知灼见为我提供了进一步反思与完善的宝贵视角。

最后，将我最深沉的感恩献给我的家人与挚友。感谢我的父母，在我二十载求学之路上无条件地支持我的每一个选择，用最朴素的爱与坚韧，为我撑起了一片可以安心追梦的天空，你们是我坚实的后盾，也是我勇往直前的全部理由。感谢我的挚友晨晨晨和老黄，在无数个挑灯夜战的时刻，你们是与并肩探讨学术难题的战友；在那些倍感压力的日子里，你们又是给予我最温暖鼓励与欢笑的港湾。

此外，还要感谢那个不曾放弃的自己。感谢那个在图书馆与实验室里度过的、与困惑和灵感为伴的日夜，感谢所有为理想付出的汗水与坚持。

谨以此文，为本段路程画上最后一个句号。成长之路漫漫，此段旅程的结束亦是新篇章的开始，我将带着自己的所学所悟，继续迈进人生的下一个篇章。

攻读学位期间的研究成果

已发表论文:

- [1] 刘鸿恩,唐杨洋,崔俊锋,等.融合多尺度特征增强与多通道注意力机制的轻量化轨道分割方法[C]//中国自动化学会.2025 中国自动化大会论文集.,2025:373-378.

已发表专利:

- [2] 刘鸿恩;胡志豪;唐杨洋.等.一种永磁磁浮轨道交通实验平台. ZL 202422717495.1. 2024-12-13.

参与科研项目:

- [3] 国家自然科学基金项目: 基于制动特性自学习的磁浮列车紧密追踪协同优化控制研究.
- [4] 江西省自然科学基金项目: 永磁磁浮列车无人驾驶场景特征建模及虚拟编组控制方法(20224BAB202025).
- [5] 国家重点研发计划: 低成本小运量磁浮客货运输系统(2023YFB4302100). 参研
- [6] 江西省重大科技研发专项: 小运量永磁悬浮轨道交通系统关键技术研究(20232ACE01011).
- [7] 江西省重点实验室: “磁浮轨道交通装备江西省重点实验室(2020SSY050), 江西理工大学” 英文名称: Jiangxi Provincial Key Laboratory of Maglev Rail Transit Equipment.